CURSO IA AVANZADA · n8n · COMISIÓN 97490

Pre-entrega Módulo 2 · Checkpoint 2

Orquestación Multi-Agente Distribuida

Asistente de Pañol v2: patrón Manager-Worker con sub-workflows en n8n, con contrato de datos, enrutamiento por intención y trazabilidad

01 Síntesis ejecutiva
02 Arquitectura del sistema
03 Workflow Manager
04 Workers (sub-workflows)
05 Handoff: nodo Execute Workflow
06 Esquema de datos Manager ↔ Worker
07 Criterio de enrutamiento
08 Ejecución de punta a punta
09 Log de trazabilidad
10 Testing de regresión
11 Robustez: errores, time-out y escape
12 Lecciones aprendidas y próximos pasos

ALUMNO
Mario Suarez

PROYECTO INTEGRADOR
Asistente de Pañol · Grupo DISAL Villa Mercedes

FECHA
11/10/2026 · n8n 2.26.7 self-hosted

01 Síntesis ejecutiva

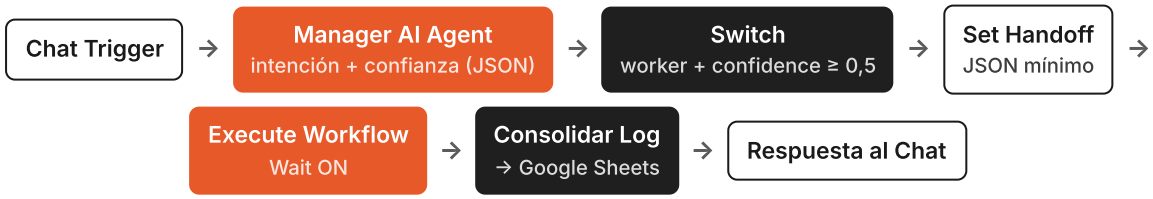
El agente monolítico del Módulo 1 se transformó en una **red modular de tres workflows**. Un **Manager** interpreta la intención del usuario dentro de una taxonomía cerrada y delega en **dos Workers especialistas** mediante el nodo Execute Workflow. Cada delegación usa un contrato de datos JSON explícito, y cada ejecución queda registrada en un log de auditoría en Google Sheets.

Requisito de la consigna	Implementación	Estado
Manager con trigger + clasificador semántico	Chat Trigger → *Manager AI Agent* con Structured Output Parser y taxonomía cerrada de 5 intenciones y 3 destinos	Cumple
≥ 2 Workers en lienzos separados	*Worker Stock Lookup* y *Worker Notificacion Responsable*, cada uno con Execute Workflow Trigger y Set de salida	Cumple
Handoff JSON + Wait for child to finish	Set de handoff (JSON mínimo) → Execute Workflow con *Workflow Inputs* definidos y *Wait For Sub-Workflow Completion* = ON	Cumple
Log de trazabilidad	*Consolidar Log* → Google Sheets (`Log_Orquestacion`): Worker invocado, parámetros enviados y respuesta	Cumple
Anti pasillo de la muerte	Set antes de cada Execute Workflow: 6–7 campos escalares, sin historial ni binarios	Cumple
Time-out y manejo de fallos	Timeout 60 s por Worker, retry ×2, ramas de error con contrato `status: error`, escape humano	Cumple
Taxonomía cerrada + vías de escape	Switch con salida Fallback → *escape_humano*; las fallas de Workers también escalan	Cumple
Testing de regresión	5 rutas probadas desde el Manager (éxito, derivación, fuera de alcance, ambigüedad, caída simulada); 1 hallazgo corregido	Cumple

RESULTADO

Todas las rutas terminaron con una respuesta integrada al chat y una fila de auditoría. Ante una caída simulada del LLM del Worker de stock, el sistema **no se bloqueó**: derivó el caso al Responsable de Pañol por correo y le informó la situación al usuario.

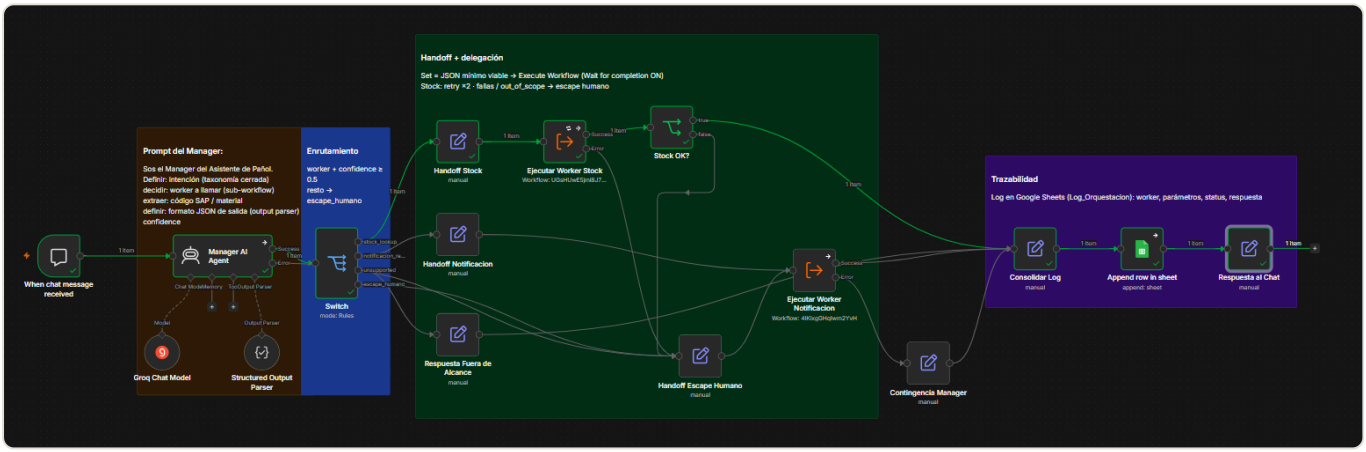
02 Arquitectura del sistema



Workflow	Rol	Tarea atómica	Conectores
Manager Asistente Pañol – M2	Orquestador (cerebro)	Interpreta, decide a qué Worker delegar, arma el handoff, consolida y registra. No consulta stock ni envía correos.	Groq (gpt-oss-20b) · Sheets (log)
Worker Stock Lookup – M2	Especialista de lectura	Consulta el maestro de stock y responde con datos verificados (agente del M1 encapsulado).	Groq (gpt-oss-120b) · Sheets en solo lectura
Worker Notificacion Responsable – M2	Especialista de redacción	Redacta y envía el aviso al Responsable de Pañol. Se reutiliza para derivaciones y para el escape humano.	Groq (gpt-oss-120b) · Gmail

Diseño híbrido: el LLM solo interpreta el lenguaje natural. A quién se delega lo decide un Switch determinista, con costo cero en tokens y auditable. El Worker de Notificación es una "habilidad reutilizable": lo invocan tres rutas distintas.

03 Workflow Manager (orquestador principal)



Captura 1. Lienzo completo del Manager con los nodos Execute Workflow (*Ejecutar Worker Stock* y *Ejecutar Worker Notificacion*). El recorrido en verde corresponde a una consulta de stock exitosa.

TRIAJE

Manager AI Agent con un prompt de 5 secciones (rol, Workers disponibles, intenciones permitidas, JSON de ejemplo y reglas). Max Iterations 3 y Output Parser con `jsonSchemaExample`.

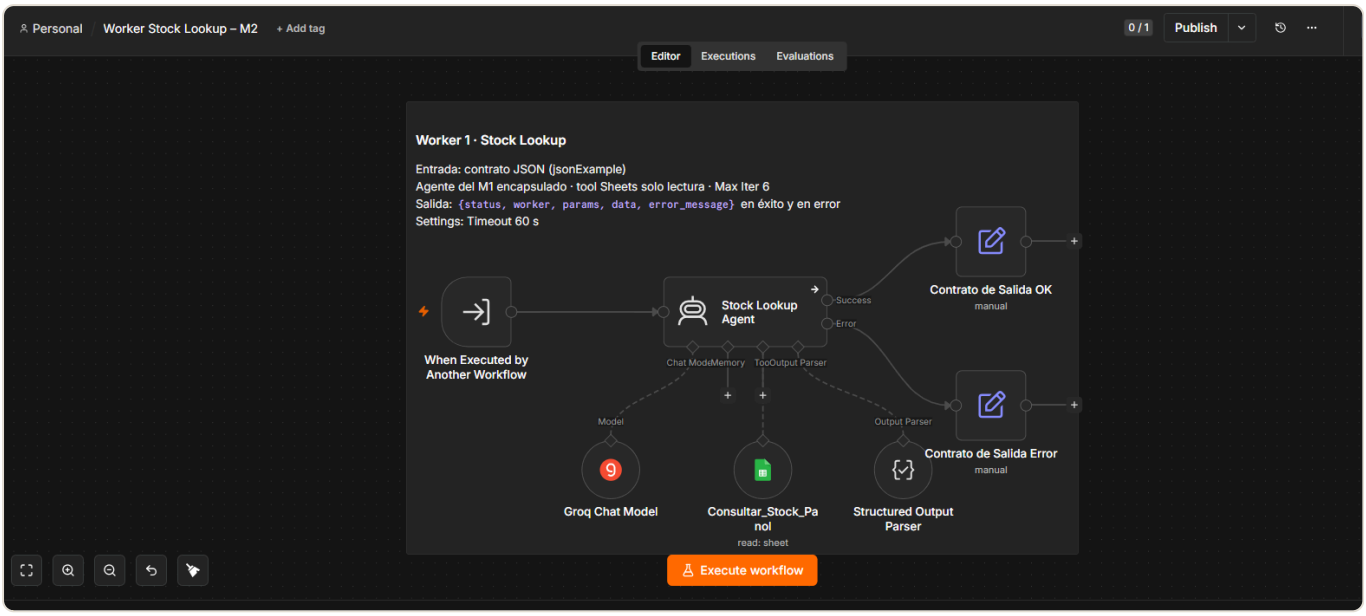
DELEGACIÓN

Un Set de handoff por destino + Execute Workflow (Wait ON). Si el Worker de stock devuelve algo distinto de `success`/`not_found`, se escala.

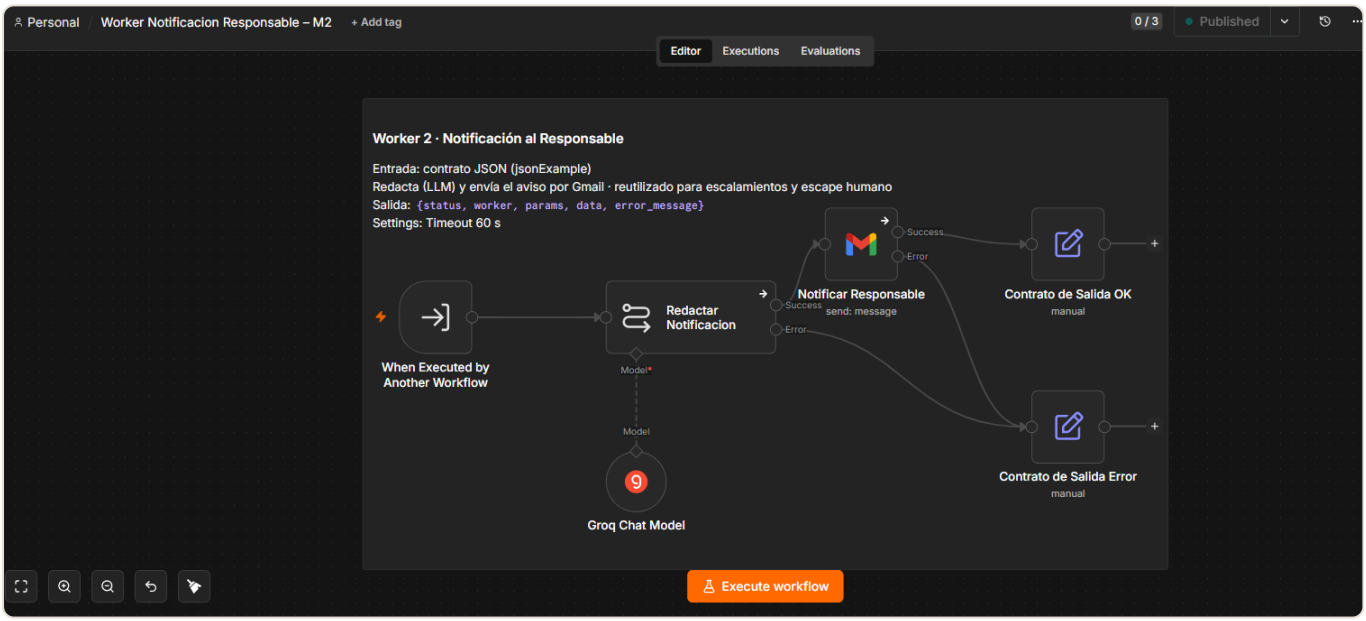
CONTINGENCIA

Las salidas de error del Manager y de los Execute nunca terminan en vacío: van al escape humano o a *Contingencia Manager*.

04 Workers como sub-workflows (especialistas quirúrgicos)



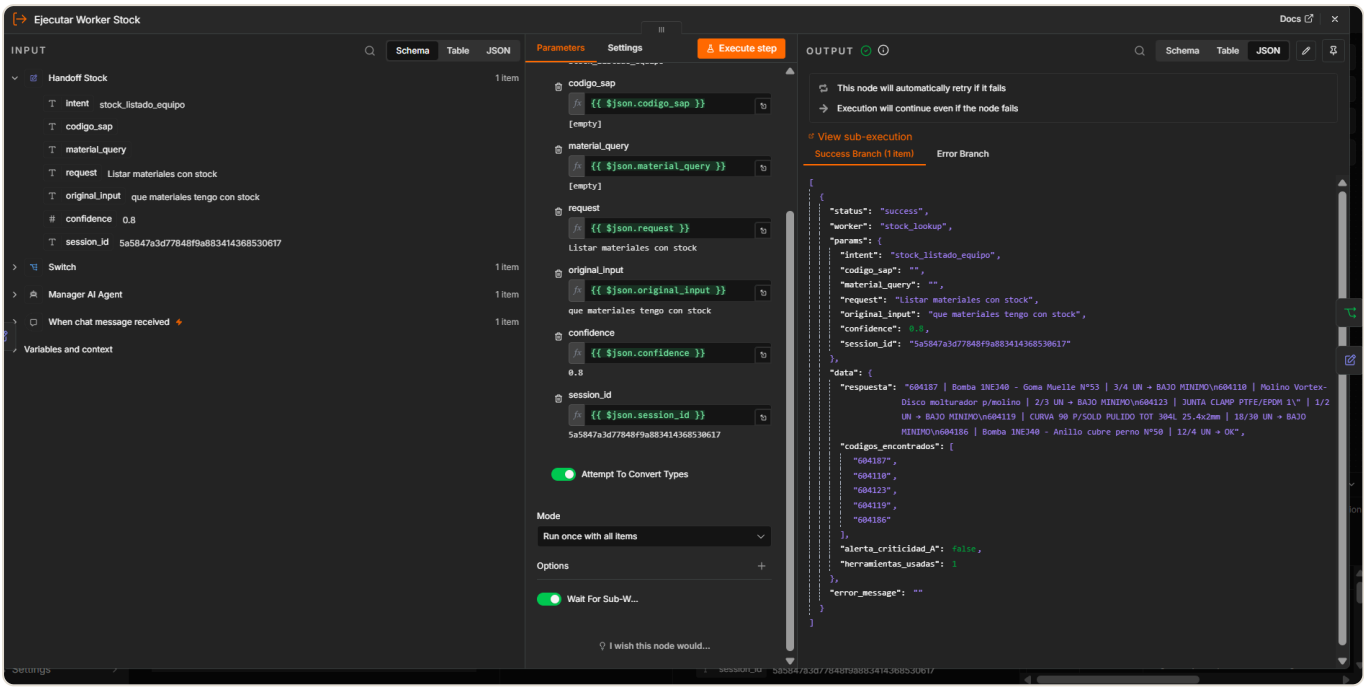
Captura 2. *Worker Stock Lookup*: Execute Workflow Trigger (entrada definida por JSON de ejemplo) → AI Agent con tool de Sheets en solo lectura y Output Parser → *Contrato de Salida OK* / *Contrato de Salida Error*.



Captura 3. *Worker Notificacion Responsable*: Execute Workflow Trigger → Basic LLM Chain (redacción) → Gmail → *Contrato de Salida OK*. Los errores de la redacción o del envío van a *Contrato de Salida Error*.

Los dos Workers son agnósticos del Manager: no saben quién los llama, solo cumplen su contrato de entrada y salida. Cada uno tiene Timeout Workflow = 60 s y está publicado de forma independiente.

05 Handoff: configuración del nodo Execute Workflow



Captura 4. *Ejecutar Worker Stock*. A la izquierda, el INPUT con el JSON mínimo que armó *Handoff Stock*. Al centro, los 7 *Workflow Inputs* mapeados, *Attempt To Convert Types* y **Wait For Sub-Workflow Completion = ON**. A la derecha, el OUTPUT con el resultado estructurado que devolvió el Worker (Success Branch y enlace a la sub-ejecución).

CONFIGURACIÓN DEL NODO

- Source: Database · Workflow: *From list*
- Mode: Run once with all items
- Wait For Sub-Workflow Completion: **ON**
- Attempt To Convert Types: ON (preserva `confidence` numérica)
- Settings: Retry on Fail ×2 (2 s) · On Error: *Continue (using error output)*

POR QUÉ WAIT FOR CHILD TO FINISH

El Manager se pausa hasta que el Worker devuelve el JSON. Así puede evaluar `status` (nodo *Stock OK?*) e integrar la respuesta al chat y al log en la misma ejecución.

06 Esquema de datos entre Manager y Worker

La comunicación se rige por un **contrato de interfaz en tres tramos**. Cada tramo tiene un formato fijo y documentado en el propio lienzo (JSON de ejemplo del trigger y Output Parser).

① Salida del Manager (Output Parser)

```
{
  "worker": "stock_lookup",
  "intent": "stock_disponibilidad",
  "codigo_sap": "",
  "material_query": "goma muelle N°53 bomba",
  "request": "Informar stock actual vs. mínimo,
              ubicación y estado …",
  "original_input": "¿Tenemos goma muelle N°53
                     para la bomba?",
  "confidence": 0.95,
  "motivo": "Consulta de disponibilidad …"
}
```

③ Retorno del Worker (siempre igual)

```
{
  "status": "success | not_found |
             out_of_scope | error",
  "worker": "stock_lookup",
  "params": { …eco de lo recibido… },
  "data": {
    "respuesta": "604187 | Goma Muelle N°53 …",
    "codigos_encontrados": ["604187"],
    "alerta_criticidad_A": false,
    "herramientas_usadas": 1
  },
  "error_message": ""
}
```

② Handoff Manager → Worker (Set + Workflow Inputs)

Campo	Tipo	W. Stock	W. Notificación	Propósito
`intent`	string	✔	✔	Qué se pide (taxonomía cerrada)
`codigo_sap`	string	✔	—	Búsqueda exacta, solo si el usuario lo informó
`material_query`	string	✔	—	Términos de búsqueda (descripción / equipo)
`request`	string	✔	✔	Instrucción concreta del Manager al especialista
`motivo`	string	—	✔	Justificación de la derivación al Responsable
`original_input`	string	✔	✔	Contexto compartido (evita un handoff sin contexto)
`confidence`	number	✔	✔	Auditoría y criterio de revisión
`session_id`	string	✔	✔	Trazabilidad de la conversación

MÍNIMO PRODUCTO VIABLE

Cada Worker recibe solo lo que necesita: el de stock no recibe `motivo` y el de notificación no recibe `codigo_sap` ni `material_query`. Nunca viajan el historial del chat, metadatos de n8n ni binarios.

SALIDA PREDECIBLE

El retorno tiene la misma estructura en éxito y en error. Por eso la lógica del Manager después de delegar es una sola condición sobre `status`. El eco de `params` alimenta el log sin depender de la rama ejecutada.

07 Criterio de enrutamiento

Destino (worker)	Intenciones permitidas	Ejemplos	Riesgo / acción
stock_lookup	`stock_disponibilidad` · `stock_ubicacion` · `stock_listado_equipo`	Stock, ubicación, criticidad, listados por equipo	**Bajo** automático (solo lectura)
notificacion_responsable	`gestion_material` · `consulta_comercial`	Retirar, reservar o dar de baja; precios, proveedores, plazos	**Medio/alto** decisión humana vía correo
unsupported	`unsupported`	Saludos, temas ajenos, mensajes sin contenido	**Nulo** respuesta fija, sin Workers
escape_humano (Fallback)	`revision_humana`	Confianza < 0,5, error del Manager, falla o `out_of_scope` del Worker de stock	**Escalado** Worker Notificación

1 · INTENCIÓN

El Manager elige **un** Worker. Si el mensaje mezcla stock con un pedido de retiro o una consulta comercial, prioriza `notificacion_responsable`: gana la intención que implica una acción.

2 · CONFIANZA

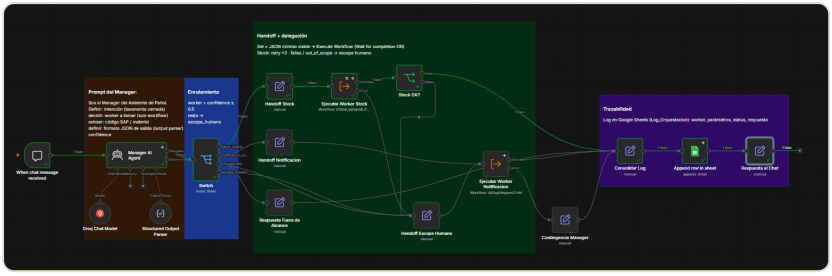
≥ 0,85 automático · **0,50–0,84** se ejecuta y el log marca `Requiere_Revision = SI` · **< 0,50** escape humano.

3 · DETERMINISMO

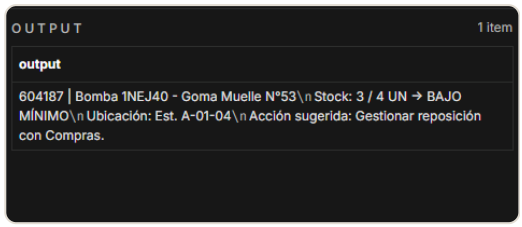
El Switch evalúa `output.worker` + `confidence ≥ 0,5`. Cualquier valor fuera de la taxonomía cae en el Fallback: no existe una ruta "sin salida".

08 Ejecución exitosa de punta a punta

Ruta A · Consulta de stock (Worker Stock)

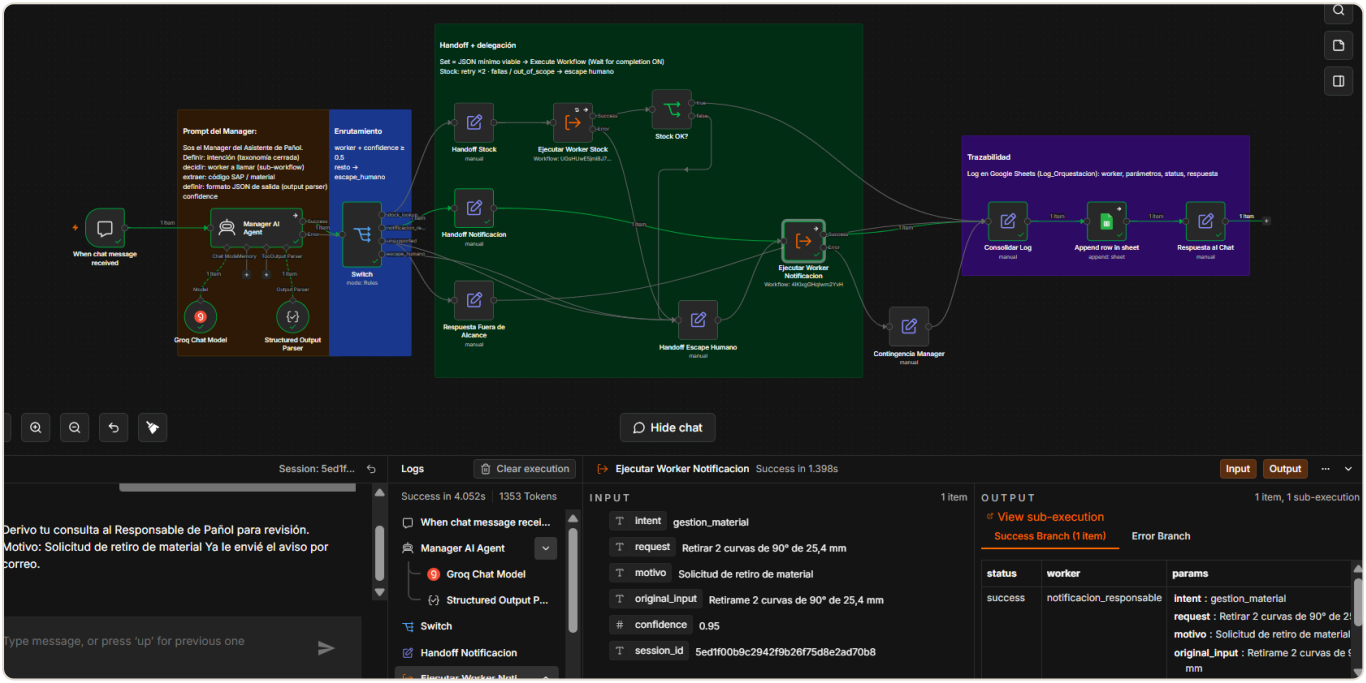


Captura 5. Recorrido verde: Manager → Switch (*stock_lookup*) → Handoff Stock → Ejecutar Worker Stock → Stock OK? (true) → Consolidar Log → Append row in sheet → Respuesta al Chat.

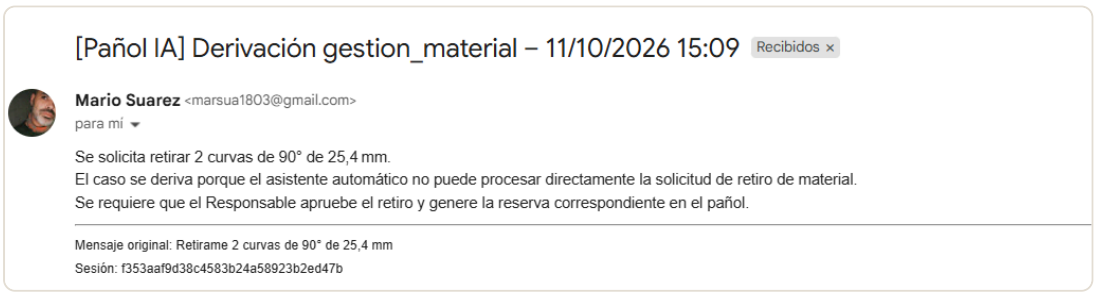


Captura 6. Respuesta integrada al chat: 604187 · Goma Muelle N°53 · 3/4 UN → BAJO MÍNIMO · Est. A-01-04 · reposición con Compras.

Ruta B · Derivación al Responsable (Worker Notificación)



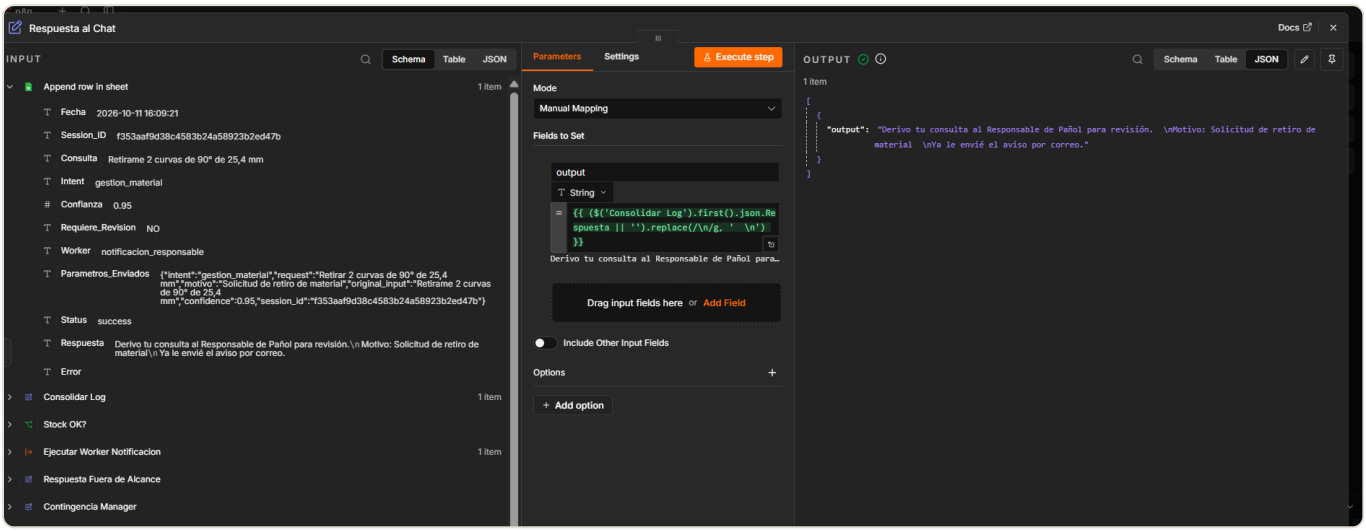
Captura 7. Mensaje "Retirame 2 curvas de 90° de 25,4 mm". Switch → *notificacion_responsable* → Ejecutar Worker Notificacion (Success en 1,4 s). En el panel se ven el handoff de 6 campos y el retorno `status: success`. Ejecución total: 4,05 s · 1.353 tokens.



Captura 8. Acción real del Worker: correo al Responsable con el pedido, el motivo de la derivación, la acción sugerida y la referencia de sesión.

09 Persistencia visual: log de trazabilidad

El nodo *Consolidar Log* normaliza la salida de cualquier ruta y *Append row in sheet* la registra en la pestaña `Log_Orquestacion`. El log está en la línea principal del Manager, así que se escribe en **todas** las ejecuciones, incluidas las de error.



Captura 9. Registro de la ruta B: Worker invocado (`notificacion_responsable`), parámetros enviados (JSON del handoff), status y respuesta devuelta, con fecha y sesión.

Registro de la ruta A (fila de `Log_Orquestacion`)

Fecha	Intent	Confianza	Revisión	Worker	Status	Respuesta
2026-10-11 15:01*	`stock_disponibilidad`	0,95	NO	`stock_lookup`	success	604187 | Bomba 1NEJ40 - Goma Muelle N°53 · 3/4 UN → BAJO MÍNIMO · Est. A-01-04

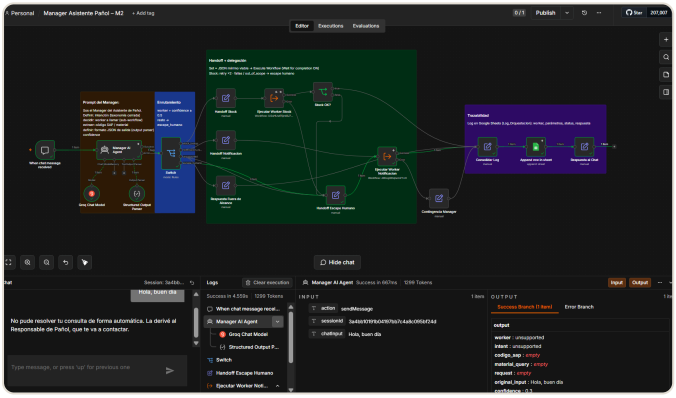
Parametros_Enviados de esa fila: `{"intent":"stock_disponibilidad","codigo_sap":"","material_query":"goma muelle N°53 bomba","request":"Informar stock actual vs. mínimo…","original_input":"¿Tenemos goma muelle N°53 para la bomba?","confidence":0.95,"session_id":"59b8c4…"}`. (*) Esta fila quedó registrada con la zona horaria por defecto de la instancia (1 h de atraso); a partir de la ruta B ya se registra en America/Argentina/Buenos_Aires (ver lecciones aprendidas).

Columna	Qué audita
`Fecha · Session_ID · Consulta`	Cuándo, en qué conversación y qué pidió el usuario
`Intent · Confianza · Requiere_Revision`	Cómo lo interpretó el Manager y si corresponde una revisión posterior (< 0,85 o status ≠ success)
`Worker · Parametros_Enviados`	A quién se delegó y con qué datos exactos
`Status · Respuesta · Error`	Qué devolvió el especialista y, si falló, por qué

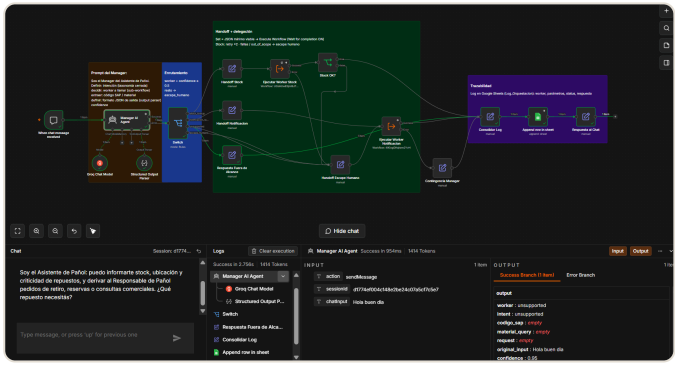
10 Testing de regresión

Todas las pruebas se hicieron manualmente desde el chat del Manager, cada una en una sesión nueva, revisando el panel de ejecución y el log.

#	Mensaje	Ruta	Resultado	Estado
1	¿Tenemos goma muelle N°53 para la bomba?	stock_lookup (0,95)	Datos verificados de la planilla; log completo	OK
2	Retirame 2 curvas de 90° de 25,4 mm	notificacion_responsable (0,95)	Correo al Responsable + derivación en el chat	OK
3	Hola, buen día	unsupported	1.ª corrida: confianza 0,3 → escape (hallazgo). Tras el ajuste: 0,95 → respuesta fija, sin Workers (2,8 s)	OK tras ajuste
4	lo de ayer	unsupported (0,95)	Pide aclaración ("¿Qué repuesto necesitás?") sin molestar al Responsable	Aceptado
5	Consulta 1 con el LLM del Worker caído (modelo inexistente)	stock_lookup → error → escape_humano	El Worker devuelve `status: error`, el Manager escala vía Worker Notificación y el usuario recibe aviso	OK

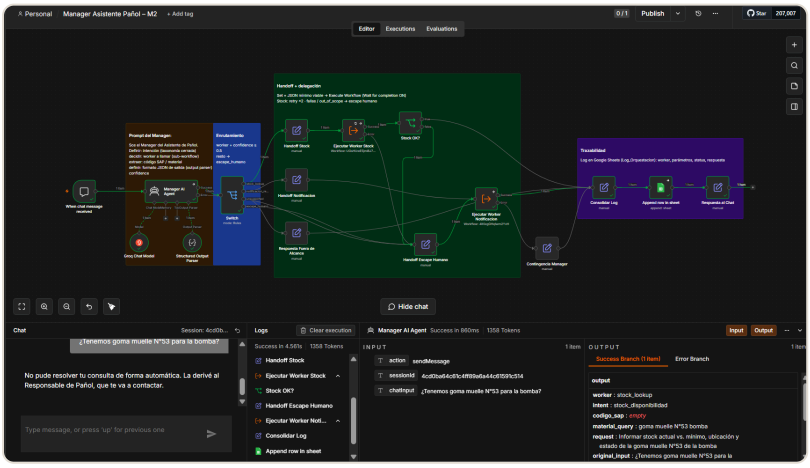


Captura 10. Hallazgo: un saludo clasificado como `unsupported` con `confidence 0,3` terminó en el escape humano.

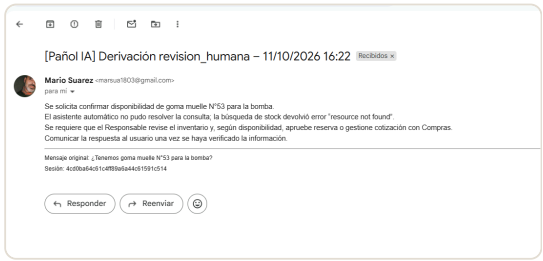


Captura 11. Después de recalibrar la regla 9 del prompt: confianza 0,95 → *Respuesta Fuera de Alcance*, sin invocar Workers.

11 Robustez: manejo de fallos, time-out y escape humano



Captura 12. Prueba 5 (caída simulada): Ejecutar Worker Stock termina en Success con el contrato de contingencia → *Stock OK?* = false → Handoff Escape Humano → Worker Notificación → log → chat.



Captura 13. Correo `revision_humana`: el Worker de Notificación informa la falla técnica ("resource not found") y la acción requerida.

Error común de la consigna	Mitigación implementada
Workflow mono-bloque	Tres workflows separados; el Manager no tiene herramientas operativas, solo delega.
Pasillo de la muerte (data stuffing)	Set de handoff con JSON mínimo antes de cada Execute Workflow (*Include Other Input Fields* = OFF).
Time-out y latencia	Settings de cada Worker: **Timeout Workflow = 60 s**; Manager = 300 s. Worker Stock con **Retry on Fail ×2**. Si se supera el timeout, el Execute sale por su rama Error → escape humano.
Falta de manejo de fallos en el Worker	Nodos críticos con *On Error: Continue (using error output)* → *Contrato de Salida Error* con `status: "error"` y `error_message`. El Worker nunca termina sin respuesta.
Bucle infinito entre especialistas	El Worker Stock responde `out_of_scope` si recibe algo que no es stock; el Manager lo escala a un humano y no lo re-deriva a otro agente.

12 Lecciones aprendidas y próximos pasos

Síntoma	Causa raíz	Solución
Un saludo terminaba en escape humano	El modelo interpretó `confidence` como "puedo resolverlo" y no como "estoy seguro de la clasificación"	Regla 9 del prompt redefinida: la confianza mide la certeza de la clasificación; un tema ajeno claro es `unsupported` con confianza alta
`confidence` llegaba como 0 al Worker	Conversión de tipos al transferir los *Workflow Inputs*	*Attempt To Convert Types* = ON en los nodos Execute Workflow
"Workflow is required" tras importar	El ID del sub-workflow cambia en cada instancia	Volver a seleccionar el Worker *From list* después de importar
Hora del log y del correo 1 h atrasada	Zona horaria por defecto de la instancia	Settings → Timezone = America/Argentina/Buenos_Aires en los 3 workflows
Saltos de línea perdidos en el chat	El chat renderiza Markdown (salto simple = espacio)	`.replace(/\n/g, ' \n')` en *Respuesta al Chat*

APRENDIZAJE CLAVE

La confianza que declara un LLM es una señal útil pero no determinista: **el control de seguridad no puede depender solo de ella**. Las vías de escape por falla técnica, que se evalúan sobre `status` con lógica fija, son las que garantizan que el sistema nunca quede sin respuesta.

EVOLUCIÓN PREVISTA DEL PROYECTO

- **M3:** memoria conversacional por `session_id`, para resolver "lo de ayer" con contexto.
- **Planner-Executor:** pedidos de varios pasos (consultar → reservar) con checkpoint HITL.
- **Worker de reserva** con aprobación humana (Send and Wait) para `gestion_material`.
- Filtrado determinista dentro del Worker Stock para escalar con maestros grandes.

Archivos opcionales adjuntos: `manager_modulo2_suarez_mario.json`, `worker1_modulo2_suarez_mario.json`, `worker2_modulo2_suarez_mario.json`.