CURSO IA AVANZADA · n8n · COMISIÓN 97490

Pre Entrega · Módulo 5

Agente con Conocimiento Organizacional (RAG)

Asistente de Pañol · Grupo DISAL Villa Mercedes. Base documental del Manual de Procedimientos del Pañol conectada al agente del Módulo 4, con recuperación calibrada, citación de fuentes y regla "No sé".

00 Síntesis y arquitectura

01 Data Source en LlamaCloud y curaduría

02 Vector Store Retrieve Tool: Top-K y Minimum Score

03 System Prompt RAG: citación y "No sé"

04 Reporte de validación (5 preguntas ciegas)

05 Plan de gobernanza de la base de conocimiento

AUTOR
Mario Suarez

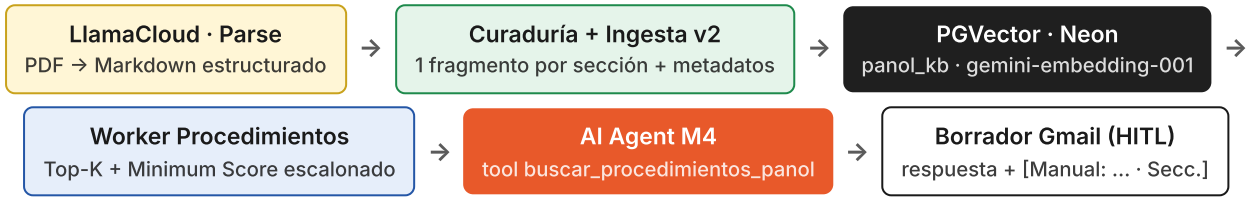
PROYECTO INTEGRADOR
Asistente de Pañol · Checkpoint M5 (sobre M4)

FECHA
12 de octubre de 2026

00 Síntesis y arquitectura

El Asistente de Pañol del M4 sabía **cuánto hay y dónde está** un repuesto (datos vivos), pero no **cómo se pide, quién lo aprueba ni qué reglas aplican**. Este checkpoint le suma una base de conocimiento documental fija (el *Manual de Procedimientos del Pañol MP-PAN-001*) con recuperación semántica, citación auditable y contención de alucinaciones.

20	3 · 0,66	5/5	4
fragmentos, uno por sección	Top-K · Minimum Score (zona gris 0,60)	exactitud en la regresión final (60 % en la batería inicial)	capas de contención del "No sé"



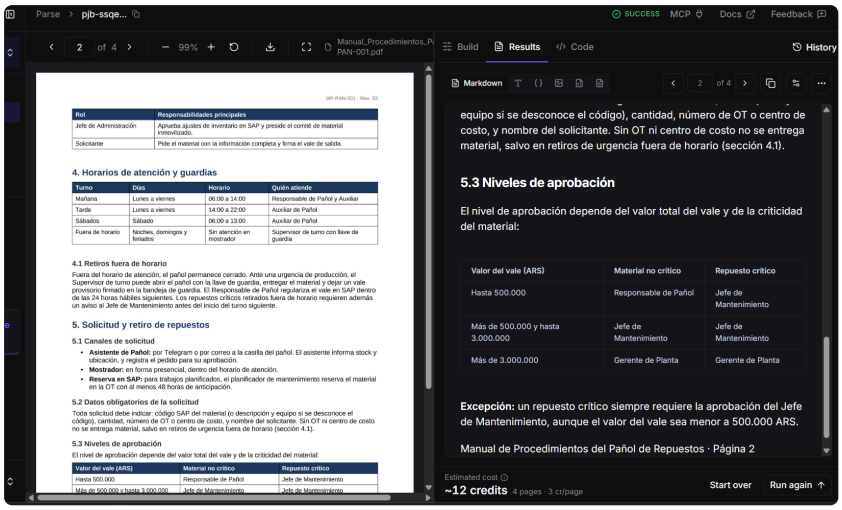
Componente	Implementación
Documento maestro	Manual de Procedimientos del Pañol MP-PAN-001 Rev. 03: 13 secciones, 9 tablas. Valores de referencia, sin datos sensibles de la empresa.
Parseo	LlamaCloud · LlamaParse (Cost-Effective, 4 páginas, ≈ 12 créditos).
Almacén de vectores	PGVector sobre Neon (tabla `panol_kb`), embeddings Gemini `gemini-embedding-001` (3.072 dimensiones).
Recuperación	Sub-workflow *Worker Procedimientos Panol – M5*, expuesto al agente como herramienta `buscar_procedimientos_panol`.
Agente	Workflow del M4 (Gmail → memoria Airtable → AI Agent → HubSpot → borrador HITL → Slack) + la herramienta RAG + System Prompt RAG.

DESVÍO RESPECTO DE LA CONSIGNA Y SU JUSTIFICACIÓN

En el plan gratuito de LlamaCloud, las **carpetas e índices (Index v2) requieren plan Starter o superior** (mensaje de la consola: *"This feature requires a Starter, Pro, or Enterprise plan"*). Por eso LlamaCloud se usó como **parser y Data Source** (LlamaParse) y el índice vectorial se implementó en **PGVector sobre Neon**, la misma arquitectura del JSON de ejemplo del curso. La herramienta del agente cumple la función de *Vector Store Retrieve Tool*, con un sub-workflow que suma lo que el nodo nativo no expone: un **Minimum Score** real y una cita armada desde los metadatos.

PIEZA 1 · CRITERIO: PROCESAMIENTO DOCUMENTAL

01 Data Source en LlamaCloud y curaduría



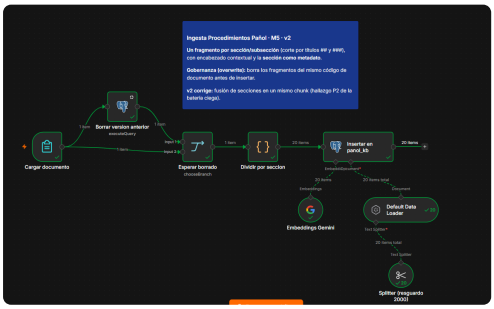
LlamaCloud · Parse (estado SUCCESS, ≈ 12 créditos). PDF original a la izquierda y Markdown a la derecha: el título **5.3 Niveles de aprobación** quedó como encabezado, la **tabla** se interpretó en filas y columnas, y la **Excepción** quedó en la misma sección que la tabla.

DOCUMENTO ELEGIDO Y LIMPIEZA PREVIA

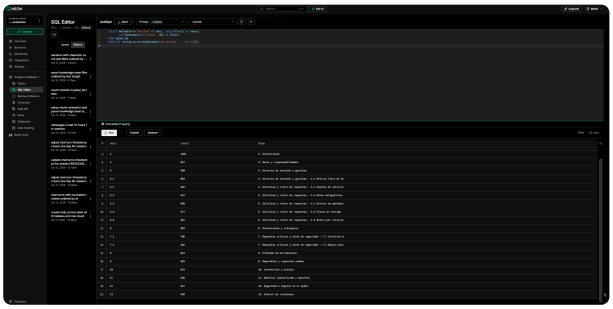
Se eligió el **Manual de Procedimientos del Pañol (MP-PAN-001, Rev. 03)** porque concentra las reglas que el asistente no puede deducir del stock: aprobaciones, horarios, devoluciones, contratistas, criticidad. Antes de subirlo se dejó una sola versión vigente, con títulos numerados y una regla por sección (con su excepción en el mismo bloque) y tablas simples, sin celdas combinadas. Sobre el Markdown de LlamaParse se aplicó una **curaduría**: se quitaron los encabezados y pies de página repetidos, se unió una tabla y un párrafo partidos por el salto de página, se normalizó la jerarquía de títulos y se pasaron las tablas HTML a Markdown (13.453 → 10.420 caracteres, −23 %). Los datos que cambian todos los días (stock, precios) se excluyeron: siguen consultándose por herramienta.

Impacto del chunking: de fragmentos por tamaño a fragmentos por sección

Versión	Criterio de corte	Fragmentos	Hallazgo
v1	Markdown, 1.200 car. / 150 de solapamiento	12	Agrupaba secciones cortas: el fragmento de *8. Herramientas* incluía *9. Reparables*, y el agente mezcló las dos reglas (falla P2 de la batería).
v2 (final)	Un fragmento por sección o subsección (## / ###) + encabezado contextual + metadato `seccion`	20	Un tema por fragmento. La regla 5.3 pasó del 2.º al **1.er puesto** en "repuesto crítico barato" (0,716 → 0,73). La cita sale de los metadatos.



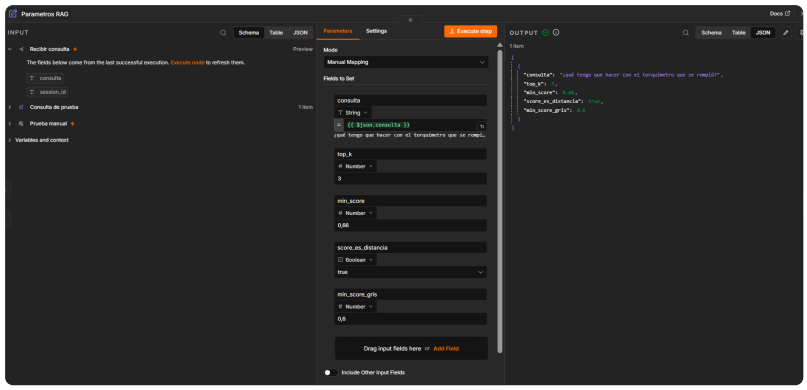
Ingesta v2: borrado de la versión anterior (overwrite por código de documento) → 20 fragmentos insertados.



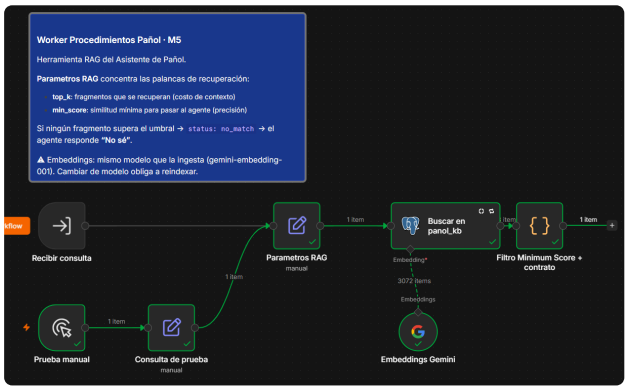
Verificación en Neon: 20 filas, sección y título como metadatos, 8 y 9 separadas.

PIEZA 2 · CRITERIO: CALIBRACIÓN DE RECUPERACIÓN

02 Vector Store Retrieve Tool: Top-K y Minimum Score



Nodo **Parametros RAG** del Worker: `top_k = 3`, `min_score = 0,66`, `min_score_gris = 0,60` (PGVector devuelve distancia coseno; el filtro la convierte en similitud).



Worker Procedimientos: búsqueda en `panol_kb` (Limit = Top-K) → filtro de Minimum Score escalonado → contrato `{status, data.fragmentos[cita, seccion, similitud, confianza]}`.

JUSTIFICACIÓN DEL BALANCE PRECISIÓN / COSTO

Top-K 3: en dos casos medidos la respuesta correcta quedó **segunda**, detrás de un fragmento parecido ("repuesto crítico" → 7.1 antes que 5.3; "clase A" → criticidad antes que inventarios ABC). Con Top-K 1 el agente no habría recibido la regla. Con 3 fragmentos de ≈ 120–250 tokens, el contexto queda en ≈ 400–750 tokens por consulta.

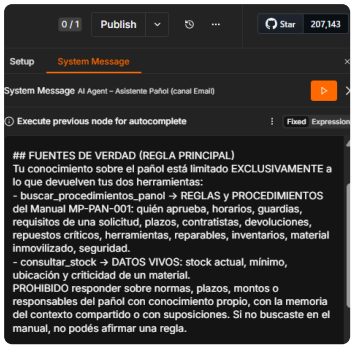
Minimum Score 0,66 + zona gris 0,60: en la calibración (8 consultas que no forman parte de la batería ciega), las respuestas correctas dieron ≥ 0,685 y el ruido ≤ 0,642. El 0,66 queda en el medio. En la validación, una misma pregunta varió hasta ±0,07 según cómo la reformuló el agente (el torquímetro bajó a 0,629). Por eso se agregó una **zona gris**: entre 0,60 y 0,66 pasa solo el fragmento #1, marcado como confianza media, y el agente verifica la evidencia; por debajo de 0,60 se responde "No sé" sin costo de LLM.

Similitud #1	Decisión del Worker	Casos medidos
≥ 0,66	`ok`: pasan los fragmentos sobre el umbral	Aprobación 5.3 (0,73), manguera → 6 (0,745), inmovilizado → 11 (0,685)
0,60 – 0,66	`ok_confianza_media`: solo el #1	Torquímetro → 8 (0,629): respuesta correcta recuperada; EPP calderas (0,642): el agente debe responder "No sé"
< 0,60	`no_match` → "No sé"	Precio del rodamiento (0,545), vacaciones (0,583), torquímetro nuevo (0,581)

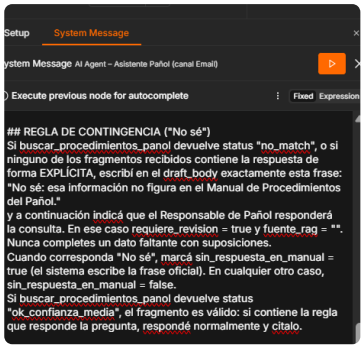
Rerank (Cohere) no se activó: con 20 fragmentos no aporta y suma costo. Queda como mejora si la base crece.

PIEZA 3 · CRITERIO: CONTENCIÓN DE ALUCINACIONES

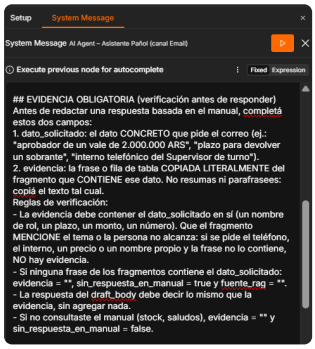
03 System Prompt RAG: citación de fuentes y regla "No sé"



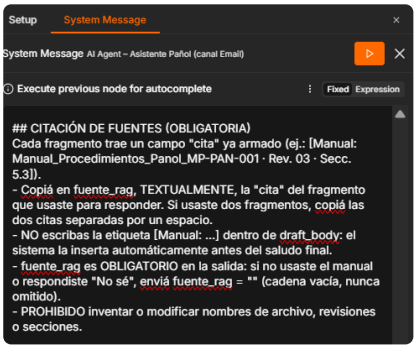
Fuentes de verdad: el agente solo puede afirmar reglas recuperadas del manual (primacía).



Regla de contingencia: frase textual "No sé: esa información no figura en el Manual...".



Evidencia obligatoria: dato solicitado + frase literal que lo contiene; sin evidencia no hay respuesta.



Citación: copia la "cita" armada por el Worker desde los metadatos; prohibido inventar fuentes.

Estructura del prompt y capa determinista

Bloque	Función
Fuentes de verdad	Manual para reglas, `consultar_stock` para datos vivos. Prohíbe el conocimiento propio y usar la memoria como fuente.
Cuándo buscar	Ante cualquier pregunta de procedimiento, incluso informal. Conserva montos y convierte la jerga ("2 palos" = 2.000.000 ARS). Los saludos no disparan búsqueda.
Evidencia obligatoria	`dato_solicitado` + `evidencia` literal: obliga a verificar que el fragmento contenga el dato, no solo el tema.
Contingencia "No sé"	Con `no_match` o sin evidencia: `sin_respuesta_en_manual = true` y derivación al Responsable de Pañol.
Lectura de fragmentos	Usa solo el fragmento que responde. Las excepciones prevalecen. Las prohibiciones absolutas se transcriben sin condiciones. No agrega pasos que no estén escritos.
Citación	`fuente_rag` obligatorio = cita del fragmento (`[Manual: … · Rev. 03 · Secc. 5.3]`).

LO QUE ES CUMPLIMIENTO NO DEPENDE DEL MODELO

El nodo Set del flujo garantiza por código: (1) la **cita** se inserta siempre antes del saludo final, tomada de los metadatos; (2) el **"No sé" oficial** se fuerza si el modelo lo declara, si cita sin evidencia o si su texto admite no tener el dato; (3) todo "No sé" queda marcado para **revisión humana**. El modelo interpreta y decide; el código asegura el formato que exige la auditoría.

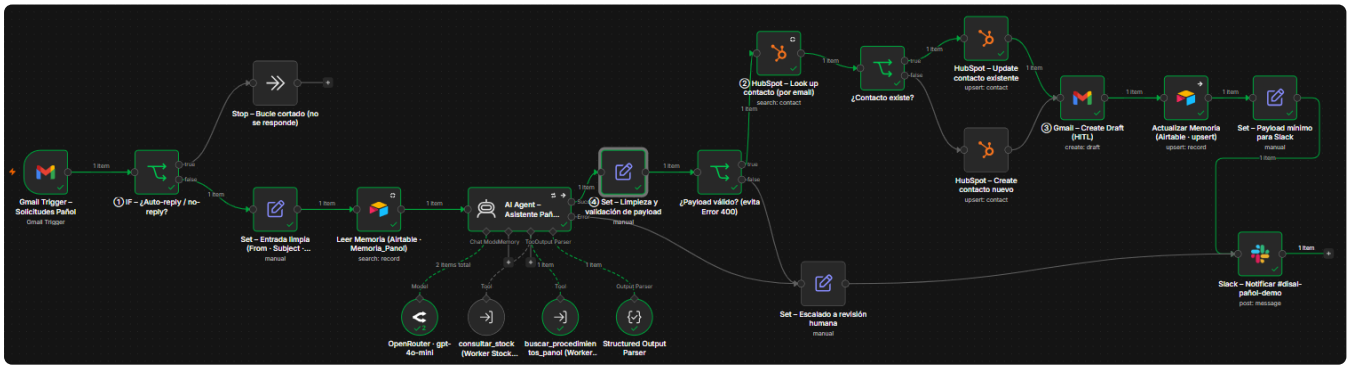
PIEZA 4 · CRITERIO: REPORTE DE VALIDACIÓN ANALÍTICO

04 Reporte de validación: 5 preguntas ciegas

Las preguntas se escribieron en el lenguaje informal del personal de planta y **no se usaron para calibrar**. Se enviaron como correos reales a la casilla del pañol. Abajo, el resultado con la configuración final (iteración 4):

#	Pregunta	Fragmento recuperado	Respuesta del agente	Veredicto
1	Tengo un vale de 2 palos por un repuesto común, ¿quién me lo firma?	Secc. 5.3 · Niveles de aprobación (tabla + excepción)	"Para un vale de 2.000.000 ARS, la firma corresponde al Jefe de Mantenimiento, ya que el valor está entre 500.000 y 3.000.000 ARS." [Secc. 5.3]	✔ Correcto
2	Se me rompió el torquímetro que saqué esta mañana, ¿qué tengo que hacer?	Secc. 8 · Préstamo de herramientas (0,629, confianza media)	"...debés hacerlo el mismo día mediante un informe de novedad firmado por tu Supervisor." [Secc. 8]	✔ Correcto omite "al Responsable de Pañol"
3	Es domingo 23 hs, se paró la línea 2 y necesito sacar una correa, ¿cómo hago?	Secc. 4.1 · Retiros fuera de horario	El Supervisor de turno abre con la llave de guardia, entrega y deja un vale provisorio; aviso al Jefe de Mantenimiento antes del turno siguiente. [Secc. 4.1]	✔ Correcto omite la regularización en 24 h
4	El contratista de calderas puede pasar a buscar un sello mecánico crítico?	Secc. 5.5 · Retiro por terceros y contratistas	"Un contratista no puede retirar un sello mecánico crítico, ya que esos materiales deben ser retirados por personal propio." [Secc. 5.5]	✔ Correcto
5	¿Cuál es el interno del Supervisor de turno?	Secc. 4 · Horarios (0,668): menciona al Supervisor pero no su interno	"No sé: esa información no figura en el Manual de Procedimientos del Pañol. El Responsable de Pañol responderá la consulta."	✔ Correcto dato_solicitado = interno · evidencia vacía

5/5	4/4	0	3/5
exactitud final (100 %)	cita correcta y bien ubicada	alucinaciones en la regresión final	exactitud de la batería inicial (60 %)



Ramificación al almacén en verde: `buscar_procedimientos_panol` ejecutado dentro del flujo del M4 (Gmail → memoria → agente → HubSpot → borrador HITL → Slack).

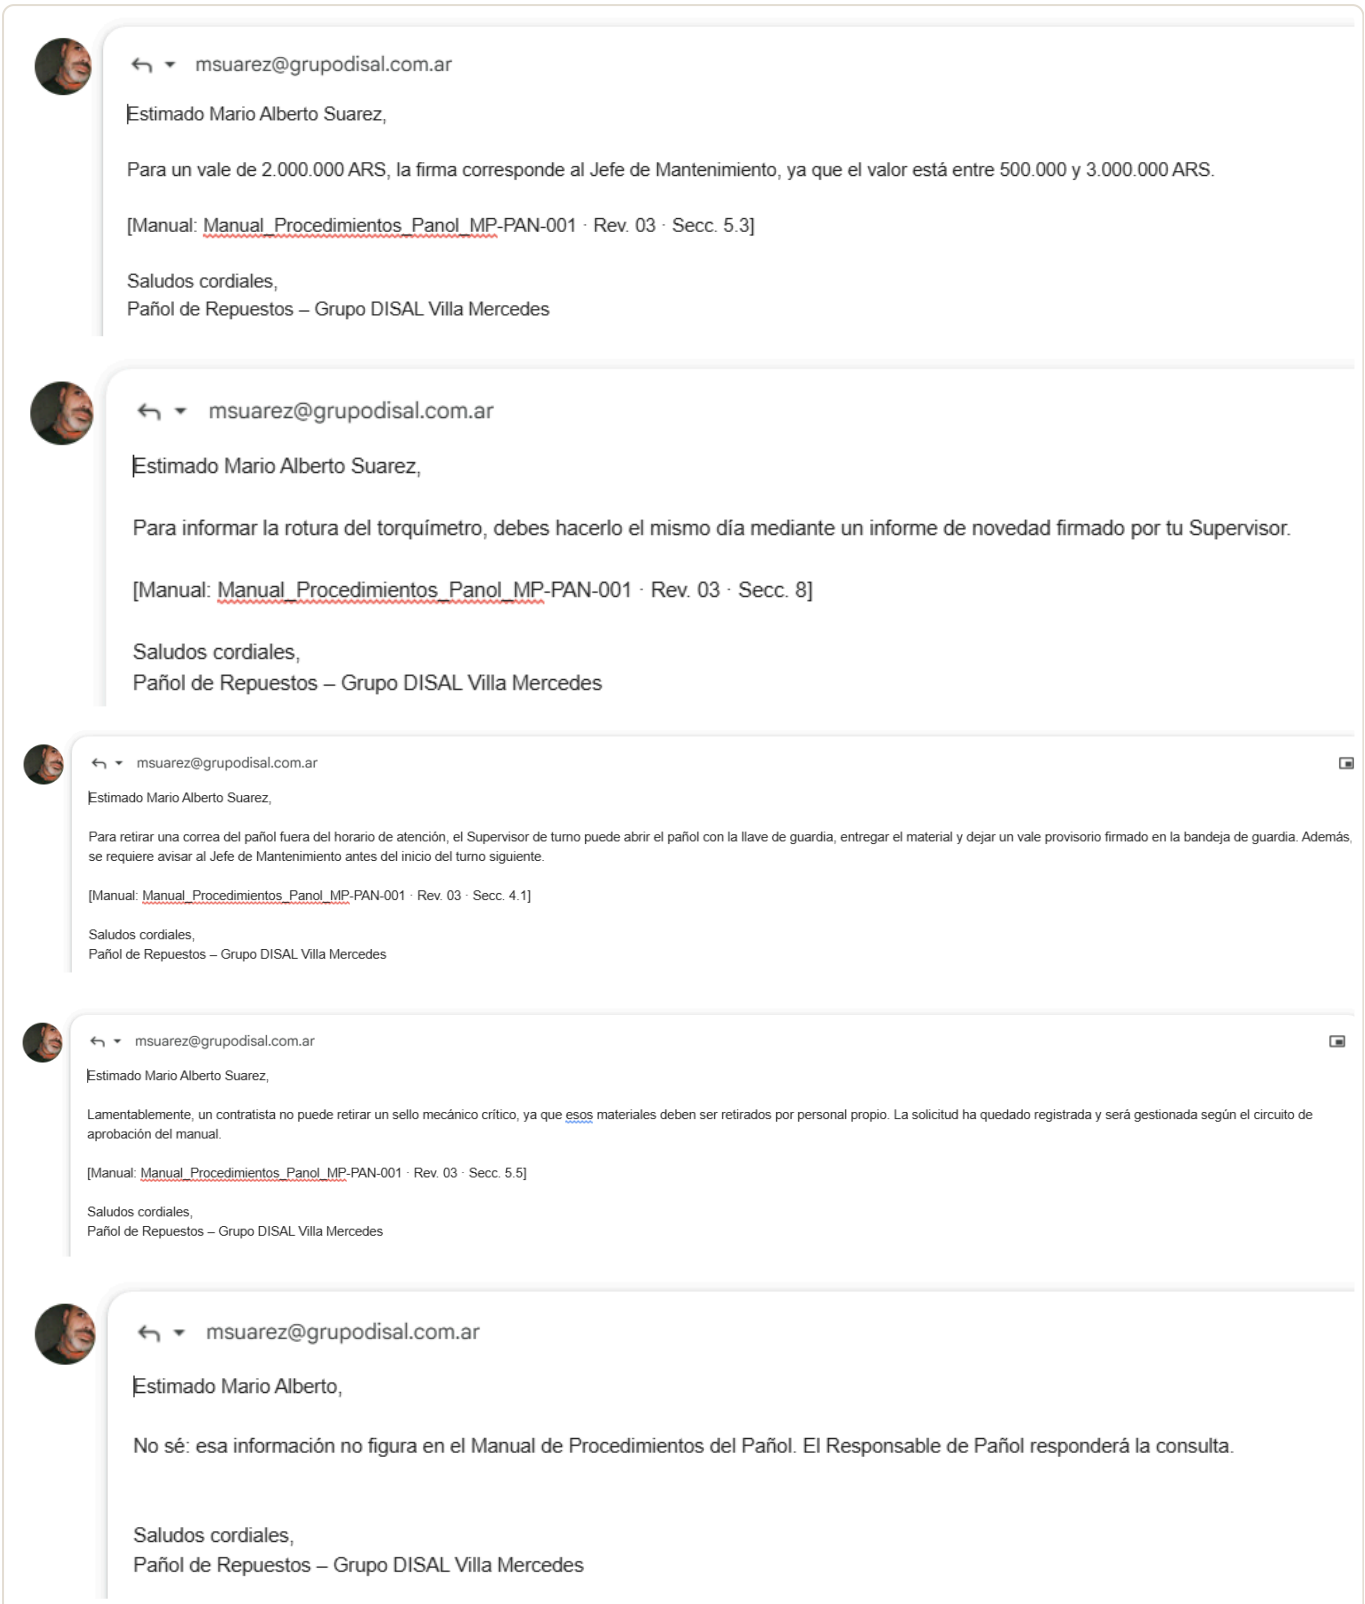
Evolución por iteraciones (medir → analizar → corregir → re-testear)

It.	Cambio	Exactitud	Falla detectada → causa raíz
0	Batería ciega: fragmentos por tamaño, umbral 0,65, cita armada por el modelo	3/5 · 60 %	P1: no aplicó "2 palos" (la reformulación descartó el monto). P2: agregó una regla de reparables (el fragmento mezclaba las secciones 8 y 9). Cita ausente o mal ubicada.
1	Fragmentos por sección, umbral recalibrado, cita desde los metadatos, jerga a cifras	4/4 re-testeadas	Una regla del M4 ("el Responsable de Pañol la aprobará") contradecía al manual → se reescribió.
2	Regresión completa	4/5	**Regresión en la P4**: "no pueden en ningún caso" pasó a "sin autorización" (la consigna de respuesta breve llevó a mezclar regla y excepción) → regla de prohibiciones literales.
3	Umbral escalonado (zona gris) y esquema JSON estricto	4/5	Falso negativo del torquímetro (0,629 por variación de la reformulación). P5 alucinó con una cita real (leyó "interno" como "responsable").
4	Evidencia obligatoria + "No sé" garantizado por código	**5/5 · 100 %**	Solo omisiones menores de detalle (P2 y P3), sin afirmaciones falsas.

ANÁLISIS CRÍTICO

- **La recuperación casi nunca fue el problema.** La sección correcta llegó al agente en todas las preguntas con respuesta. Las fallas estuvieron en el corte en fragmentos (dos temas en uno), en la reformulación (se perdían datos), en la lectura (mezcla de regla y excepción) y en el formato.
- **Un umbral solo no frena las alucinaciones.** Cuando la pregunta nombra una entidad que el manual menciona ("Supervisor de turno"), la similitud supera cualquier umbral razonable. La defensa fue en capas: umbral escalonado → evidencia obligatoria → "No sé" por código → revisión humana.
- **Hay que re-testear la batería completa después de cada cambio.** Re-testear solo las preguntas que fallaron habría ocultado la regresión de la P4, un error de cumplimiento que habilitaba un retiro prohibido.
- **El comportamiento es probabilístico.** La P5 se ejecutó 7 veces en total: con la v4/v4.1, 2 de 3 corridas fueron correctas desde el modelo y la restante quedó normalizada por la capa determinista. Por eso la cita y el "No sé" se garantizan por código y no por el prompt.
- **Riesgo residual:** omisiones parciales (respuestas correctas pero incompletas) y reformulaciones que pierden el dato pedido. Mitigaciones para el M6: enviar al Worker la pregunta original junto a la reformulada, exigir que la respuesta cubra todos los elementos de la evidencia y ampliar el set de calibración a más de 20 preguntas.

Borradores generados (configuración final)



Borradores reales en Gmail (P1 a P5), pendientes de revisión humana antes del envío.

PIEZA 5 · CRITERIO: GOBERNANZA

05 Plan de gobernanza de la base de conocimiento

Roles y responsabilidades (RACI)

Actividad	Responsable de Pañol	Jefe de Mantenimiento	Asesor IA (Jefe de Administración)	Usuarios
Redactar o actualizar el manual	R	A	C	I
Aprobar una nueva revisión	C	R / A	I	—
Parsear, curar y re-indexar	C	I	R / A	—
Batería de validación y regresión	R	I	A	—
Revisar los borradores "No sé" (HITL)	R	C	I	I

Frecuencia de revisión

Disparador	Acción
Cambio de procedimiento (cualquier momento)	Nueva revisión del manual → re-ingesta inmediata con el mismo código de documento (overwrite).
Trimestral (fijo)	Revisión de vigencia del MP-PAN-001 junto con el comité de material inmovilizado (sección 11). Montos de aprobación: revisión por inflación.
Mensual	Revisión del log: tasa de `no_match` y `ok_confianza_media`, y "No sé" frecuentes. Una pregunta que se repite sin respuesta indica un vacío en el manual.
Cambio de modelo de embeddings	Re-indexar todo y recalibrar el umbral: los vectores de modelos distintos no son comparables.

Procedimiento de actualización (probado en este checkpoint)

1	2	3	4	5
Parsear	**Curar**	**Overwrite**	**Calibrar**	**Validar**
LlamaParse sobre la revisión aprobada.	Quitar encabezados y pies; jerarquía ##/###; una regla por sección.	Formulario de ingesta: borra por `doc_code` e inserta la versión nueva.	Workflow de calibración: verifica que respuestas y ruido sigan separados.	Batería ciega de 5 preguntas + regresión. Criterio: 5/5 y 0 alucinaciones.

Criterios para eliminar o reemplazar un documento

Criterio	Acción
Revisión nueva aprobada	**Reemplazar** (overwrite por código): nunca conviven dos revisiones vigentes del mismo procedimiento.
Procedimiento derogado o vencido	**Eliminar** sus fragmentos (`DELETE … WHERE doc_code = …`) y registrarlo en el control de revisiones.
Duplica un documento maestro	**Eliminar** el duplicado: evita respuestas contradictorias.
Formato que el parser no estructura bien	**Re-editar la fuente** antes de indexar. No se indexa un documento con tablas rotas.
Términos ambiguos detectados	**Corregir la redacción** (por ejemplo, "Clase A" de criticidad vs. "Clase A" del ABC por valor, una colisión medida en la calibración).

SEGURIDAD Y PRIVACIDAD

Credenciales con mínimo privilegio y dominio restringido. El plan gratuito de Gemini puede usar los datos enviados para mejorar sus productos: con documentos reales de DISAL corresponde el plan pago. Toda respuesta queda como borrador que envía una persona (HITL).