CURSO IA AVANZADA · n8n · COMISIÓN 97490

Pre Entrega · Módulo 5

Agente con Conocimiento Organizacional (RAG)

Asistente de Pañol · Grupo DISAL Villa Mercedes. Base documental del Manual de Procedimientos del Pañol conectada al agente del Módulo 4, con recuperación calibrada, citación de fuentes y regla "No sé".

00 Síntesis y arquitectura

01 Data Source en LlamaCloud y curaduría

02 Vector Store Retrieve Tool: Top-K y Minimum Score

03 System Prompt RAG: citación y "No sé"

04 Reporte de validación (5 preguntas ciegas)

05 Plan de gobernanza de la base de conocimiento

AUTOR
Mario Suarez

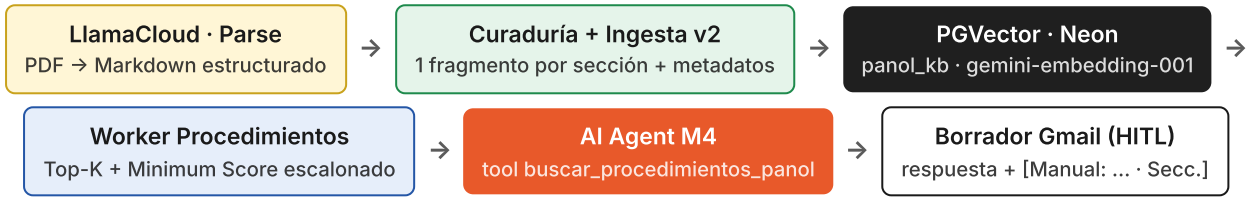
PROYECTO INTEGRADOR
Asistente de Pañol · Checkpoint M5 (sobre M4)

FECHA
12 de octubre de 2026

00 Síntesis y arquitectura

El Asistente de Pañol del M4 sabía **cuánto hay y dónde está** un repuesto (datos vivos), pero no **cómo se pide, quién lo aprueba ni qué reglas aplican**. Este checkpoint le suma una base de conocimiento documental fija (el *Manual de Procedimientos del Pañol MP-PAN-001*) con recuperación semántica, citación auditable y contención de alucinaciones.

20	3 · 0,66	60 % → 5/5	4
fragmentos, uno por sección	Top-K · Minimum Score (zona gris 0,60)	precisión ciega · regresión post-corrección	capas de contención del "No sé"



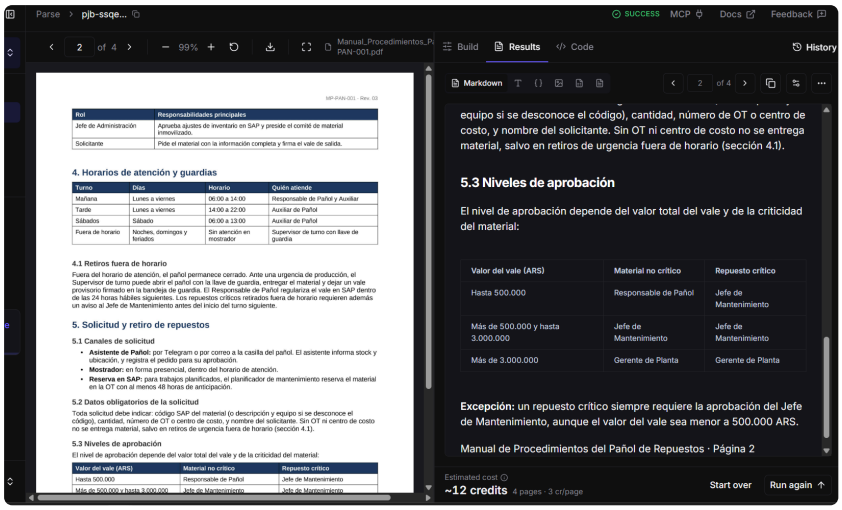
Componente	Implementación
Documento maestro	Manual de Procedimientos del Pañol MP-PAN-001 Rev. 03: 13 secciones, 9 tablas. Valores de referencia, sin datos sensibles de la empresa.
Parseo	LlamaCloud · LlamaParse (Cost-Effective, 4 páginas, ≈ 12 créditos).
Almacén de vectores	PGVector sobre Neon (tabla `panol_kb`), embeddings Gemini `gemini-embedding-001` (3.072 dimensiones).
Recuperación	Sub-workflow *Worker Procedimientos Panol – M5*, expuesto al agente como herramienta `buscar_procedimientos_panol`.
Agente	Workflow del M4 (Gmail → memoria Airtable → AI Agent → HubSpot → borrador HITL → Slack) + la herramienta RAG + System Prompt RAG.

DESVÍO RESPECTO DE LA CONSIGNA Y SU JUSTIFICACIÓN

En el plan gratuito de LlamaCloud, las **carpetas e índices (Index v2) requieren plan Starter o superior** (mensaje de la consola: *"This feature requires a Starter, Pro, or Enterprise plan"*). Por eso LlamaCloud se usó como **parser y Data Source** (LlamaParse) y el índice vectorial se implementó en **PGVector sobre Neon**, la misma arquitectura del JSON de ejemplo del curso. La herramienta del agente cumple la función de *Vector Store Retrieve Tool*, con un sub-workflow que suma lo que el nodo nativo no expone: un **Minimum Score** real y una cita armada desde los metadatos.

PIEZA 1 · CRITERIO: PROCESAMIENTO DOCUMENTAL

01 Data Source en LlamaCloud y curaduría



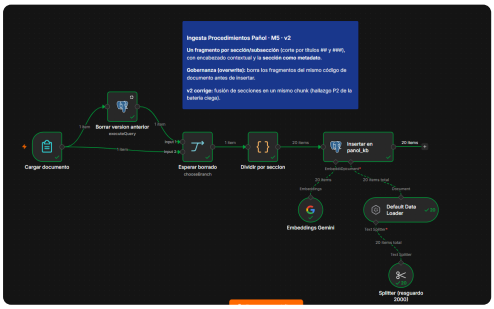
LlamaCloud · Parse (estado SUCCESS, ≈ 12 créditos). PDF original a la izquierda y Markdown a la derecha: el título **5.3 Niveles de aprobación** quedó como encabezado, la **tabla** se interpretó en filas y columnas, y la **Excepción** quedó en la misma sección que la tabla.

DOCUMENTO ELEGIDO Y LIMPIEZA PREVIA

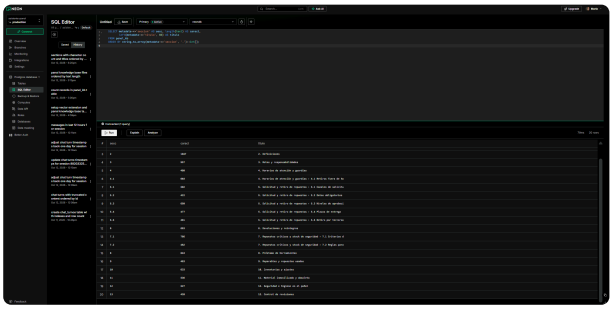
Se eligió el **Manual de Procedimientos del Pañol (MP-PAN-001, Rev. 03)** porque concentra las reglas que el asistente no puede deducir del stock: aprobaciones, horarios, devoluciones, contratistas, criticidad. Antes de subirlo se dejó una sola versión vigente, con títulos numerados y una regla por sección (con su excepción en el mismo bloque) y tablas simples, sin celdas combinadas. Sobre el Markdown de LlamaParse se aplicó una **curaduría**: se quitaron los encabezados y pies de página repetidos, se unió una tabla y un párrafo partidos por el salto de página, se normalizó la jerarquía de títulos y se pasaron las tablas HTML a Markdown (13.453 → 10.420 caracteres, −23 %). Los datos que cambian todos los días (stock, precios) se excluyeron: siguen consultándose por herramienta.

Impacto del chunking: de fragmentos por tamaño a fragmentos por sección

Versión	Criterio de corte	Fragmentos	Hallazgo
v1	Markdown, 1.200 car. / 150 de solapamiento	12	Agrupaba secciones cortas: el fragmento de *8. Herramientas* incluía *9. Reparables*, y el agente mezcló las dos reglas (falla P2 de la batería).
v2 (final)	Un fragmento por sección o subsección (## / ###) + encabezado contextual + metadato `seccion`	20	Un tema por fragmento. La regla 5.3 pasó del 2.º al **1.er puesto** en "repuesto crítico barato" (0,716 → 0,73). La cita sale de los metadatos.



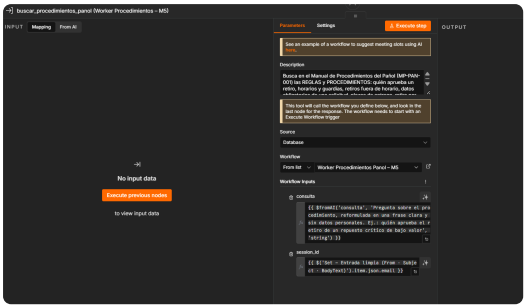
Ingesta v2: borrado de la versión anterior (overwrite por código de documento) → 20 fragmentos insertados.



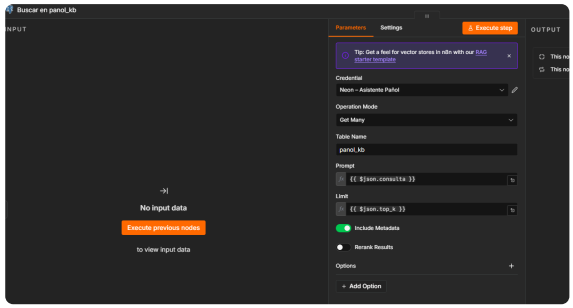
Verificación en Neon: 20 filas, sección y título como metadatos, 8 y 9 separadas.

PIEZA 2 · CRITERIO: CALIBRACIÓN DE RECUPERACIÓN

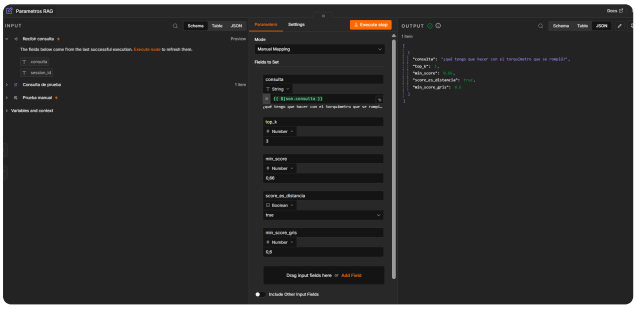
02 Vector Store Retrieve Tool: Top-K y Minimum Score



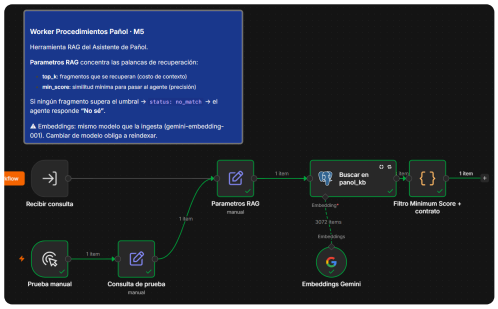
Retrieve Tool del agente · `buscar_procedimientos_panol`: nombre semántico, descripción de negocio y conexión al Worker publicado.



Nodo Vector Store (Postgres PGVector · Get Many): tabla `panol_kb`, **Limit = Top-K** (`{{ $json.top_k }}`), metadatos incluidos para la cita.



Valores configurados: `top_k = 3`, `min_score = 0,66`, `min_score_gris = 0,60` (PGVector devuelve distancia coseno; el filtro la convierte en similitud).



Worker completo: Parametros RAG → búsqueda (Top-K) → filtro de **Minimum Score** escalonado → contrato con cita.

JUSTIFICACIÓN DEL BALANCE PRECISIÓN / COSTO

Top-K 3: en dos casos medidos la respuesta correcta quedó **segunda**, detrás de un fragmento parecido ("repuesto crítico" → 7.1 antes que 5.3; "clase A" → criticidad antes que inventarios ABC). Con Top-K 1 el agente no habría recibido la regla. Con 3 fragmentos de ≈ 120–250 tokens, el contexto queda en ≈ 400–750 tokens por consulta.

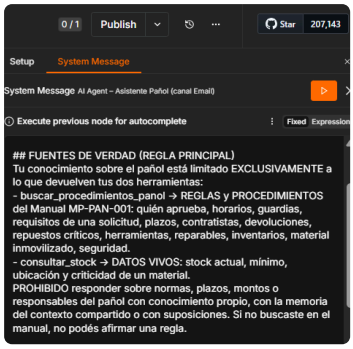
Minimum Score 0,66 + zona gris 0,60: en la calibración (8 consultas que no forman parte de la batería ciega), las respuestas correctas dieron ≥ 0,685 y el ruido ≤ 0,642. El 0,66 queda en el medio. En la validación, una misma pregunta varió hasta ±0,07 según cómo la reformuló el agente (el torquímetro bajó a 0,629). Por eso se agregó una **zona gris**: entre 0,60 y 0,66 pasa solo el fragmento #1, marcado como confianza media, y el agente verifica la evidencia; por debajo de 0,60 se responde "No sé" sin costo de LLM.

Similitud #1	Decisión del Worker	Casos medidos
≥ 0,66	`ok`: pasan los fragmentos sobre el umbral	Aprobación 5.3 (0,73), manguera → 6 (0,745), inmovilizado → 11 (0,685)
0,60 – 0,66	`ok_confianza_media`: solo el #1	Torquímetro → 8 (0,629): respuesta correcta recuperada; EPP calderas (0,642): el agente debe responder "No sé"
< 0,60	`no_match` → "No sé"	Precio del rodamiento (0,545), vacaciones (0,583), torquímetro nuevo (0,581)

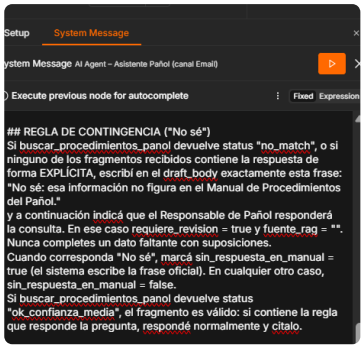
Rerank (Cohere) no se activó: con 20 fragmentos no aporta y suma costo. Queda como mejora si la base crece.

PIEZA 3 · CRITERIO: CONTENCIÓN DE ALUCINACIONES

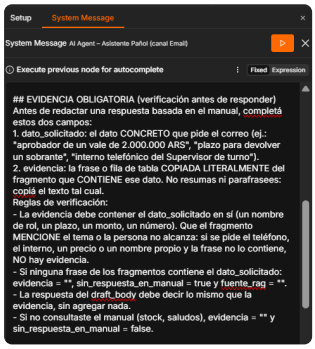
03 System Prompt RAG: citación de fuentes y regla "No sé"



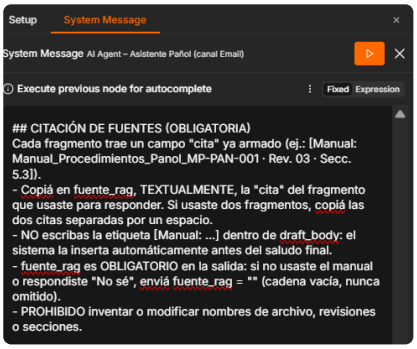
Fuentes de verdad: el agente solo puede afirmar reglas recuperadas del manual (primacía).



Regla de contingencia: frase textual "No sé: esa información no figura en el Manual...".



Evidencia obligatoria: dato solicitado + frase literal que lo contiene; sin evidencia no hay respuesta.



Citación: copia la "cita" armada por el Worker desde los metadatos; prohibido inventar fuentes.

Estructura del prompt y capa determinista

Bloque	Función
Fuentes de verdad	Manual para reglas, `consultar_stock` para datos vivos. Prohíbe el conocimiento propio y usar la memoria como fuente.
Cuándo buscar	Ante cualquier pregunta de procedimiento, incluso informal. Conserva montos y convierte la jerga ("2 palos" = 2.000.000 ARS). Los saludos no disparan búsqueda.
Evidencia obligatoria	`dato_solicitado` + `evidencia` literal: obliga a verificar que el fragmento contenga el dato, no solo el tema.
Contingencia "No sé"	Con `no_match` o sin evidencia: `sin_respuesta_en_manual = true` y derivación al Responsable de Pañol.
Lectura de fragmentos	Usa solo el fragmento que responde. Las excepciones prevalecen. Las prohibiciones absolutas se transcriben sin condiciones. No agrega pasos que no estén escritos.
Citación	`fuente_rag` obligatorio = cita del fragmento (`[Manual: … · Rev. 03 · Secc. 5.3]`).

LO QUE ES CUMPLIMIENTO NO DEPENDE DEL MODELO

El nodo Set del flujo garantiza por código: (1) la **cita** se inserta siempre antes del saludo final, tomada de los metadatos; (2) el **"No sé" oficial** se fuerza si el modelo lo declara, si cita sin evidencia o si su texto admite no tener el dato; (3) todo "No sé" queda marcado para **revisión humana**. El modelo interpreta y decide; el código asegura el formato que exige la auditoría.

PIEZA 4 · CRITERIO: REPORTE DE VALIDACIÓN ANALÍTICO

04 Reporte de validación: 5 preguntas ciegas

Las preguntas se escribieron en el lenguaje informal del personal de planta y **no se usaron para calibrar** (la calibración usó otro set de 8 consultas). Se enviaron como correos reales a la casilla del pañol. **Batería ciega original**, con la configuración tal como se construyó:

#	Pregunta	Fragmento recuperado	Respuesta del agente	Veredicto
1	Tengo un vale de 2 palos por un repuesto común, ¿quién me lo firma?	5.3 Niveles de aprobación (0,739, 1.º)	"...es el Responsable de Pañol, siempre que el valor no supere los 500.000 ARS. Si es mayor, deberá ser aprobado por el Jefe de Mantenimiento." [Secc. 5.3]	✘ **Falla de interpretación** no aplicó "2 palos" = 2.000.000
2	Se me rompió el torquímetro que saqué esta mañana, ¿qué tengo que hacer?	8 Préstamo de herramientas (0,702), fragmento que incluía también la secc. 9	"...informar al Responsable de Pañol el mismo día mediante un informe de novedad firmado por el Supervisor. La herramienta debe ser devuelta... para su reparación." (sin cita)	⚠ **Parcial** agregado sin respaldo y sin cita
3	Es domingo 23 hs, se paró la línea 2 y necesito sacar una correa, ¿cómo hago?	4.1 Retiros fuera de horario (0,724) + 7.1 Criticidad (0,742)	"...comunicarte con el Supervisor de turno, quien puede abrir el pañol y entregarte el material... informes al Jefe de Mantenimiento... antes del inicio del siguiente turno." [Secc. 4.1]	✔ **Correcto** omite el vale provisorio
4	El contratista de calderas puede pasar a buscar un sello mecánico crítico?	5.5 Retiro por terceros y contratistas (0,711, 1.º)	"El contratista no puede retirar el sello mecánico crítico, ya que este material solo puede ser retirado por personal propio." [Secc. 5.5]	✔ **Correcto**
5	¿Cuál es el interno del Supervisor de turno?	4 Horarios (0,66): menciona al Supervisor, no su interno	"No sé: esa información no figura en el Manual de Procedimientos del Pañol. El Responsable de Pañol responderá tu consulta."	✔ **Correcto** frenado por el prompt, no por el umbral

3/5	**4/4**	**2/4**	**5/5**
Precisión de la batería ciega (60 %)	precisión de recuperación: sección correcta entregada al agente	cita correcta y bien ubicada	regresión post-corrección (ver página siguiente)

ANÁLISIS CRÍTICO DE LAS FALLAS

- **P1 · Falla de interpretación, no de recuperación.** El fragmento correcto llegó primero (0,739), pero la reformulación de la consulta descartó el monto y el modelo no tradujo la jerga. Respondió la regla general en condicional. *Acción:* conservar montos al reformular, convertir la jerga a cifras y aplicar la tabla al valor concreto.
- **P2 · Falla de chunking.** El fragmento de la sección 8 contenía también la sección 9 (Reparables), y el modelo mezcló las dos reglas. *Acción:* re-ingesta con un fragmento por sección (12 → 20 fragmentos) y cita armada desde los metadatos.
- **P5 · El umbral no alcanzó.** La pregunta nombra una entidad del manual, así que la similitud (0,66) superó el umbral. La protección la dio la regla "No sé" del prompt: defensa en capas.
- **Formato · Cita inconsistente** (ausente en P2, debajo de la firma en P3). *Acción:* mover la cita al código (Set determinista).

Verificación de las acciones correctivas: regresión post-corrección (configuración final)

#	Fragmento	Respuesta del agente (configuración final)	Veredicto
1	5.3	"Para un vale de 2.000.000 ARS, la firma corresponde al Jefe de Mantenimiento, ya que el valor está entre 500.000 y 3.000.000 ARS." [Secc. 5.3]	✔
2	8 (0,629, confianza media)	"...debés hacerlo el mismo día mediante un informe de novedad firmado por tu Supervisor." [Secc. 8]	✔ omite el destinatario
3	4.1	Supervisor de turno con llave de guardia, entrega, vale provisorio, aviso al Jefe de Mantenimiento. [Secc. 4.1]	✔ omite las 24 h
4	5.5	"Un contratista no puede retirar un sello mecánico crítico... deben ser retirados por personal propio." [Secc. 5.5]	✔
5	4 (0,668), evidencia vacía	"No sé: esa información no figura en el Manual de Procedimientos del Pañol..."	✔

LECTURA CORRECTA DEL 5/5

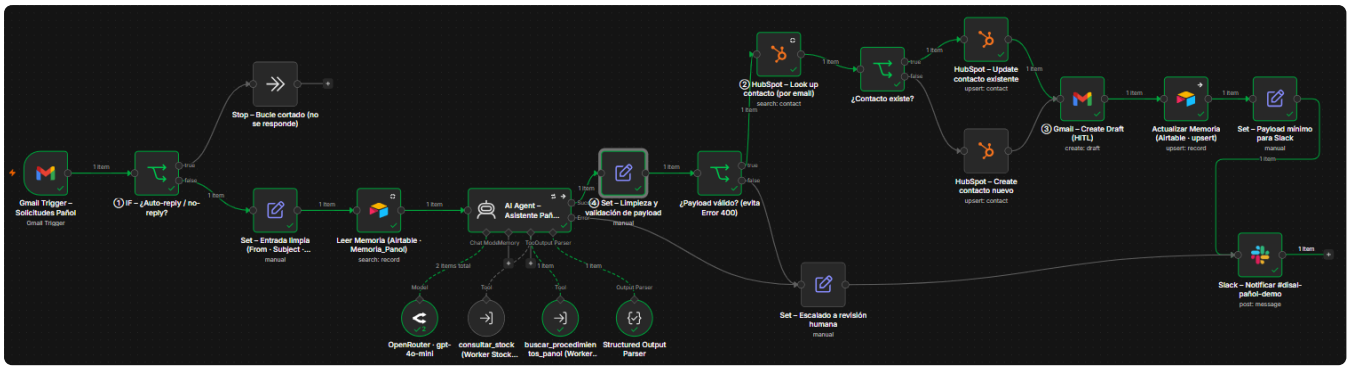
La regresión mide **si las correcciones resolvieron las fallas**, no la precisión ciega: estas 5 preguntas guiaron los ajustes, así que el 100 % está sobreajustado a ellas. **La precisión ciega del sistema es la de la batería original (60 %).** Para medir la generalización de la versión final hace falta una batería nueva, nunca usada: queda como primera acción del M6.

Evolución por iteraciones (medir → analizar → corregir → re-testear)

It.	Cambio	Precisión	Hallazgo
0	Batería ciega (configuración original)	3/5	P1 jerga, P2 chunk mezclado, cita inconsistente.
1	Fragmentos por sección, umbral recalibrado, cita desde código, jerga a cifras	4/4 re-test.	Regla del M4 que contradecía al manual → reescrita.
2	Regresión completa	4/5	**Regresión P4:** "en ningún caso" pasó a "sin autorización" → regla de prohibiciones literales.
3	Zona gris 0,60–0,66 + esquema JSON estricto	4/5	P5 alucinó con una cita real (leyó "interno" como "responsable").
4	Evidencia obligatoria + "No sé" garantizado por código	5/5	Solo omisiones menores de detalle.

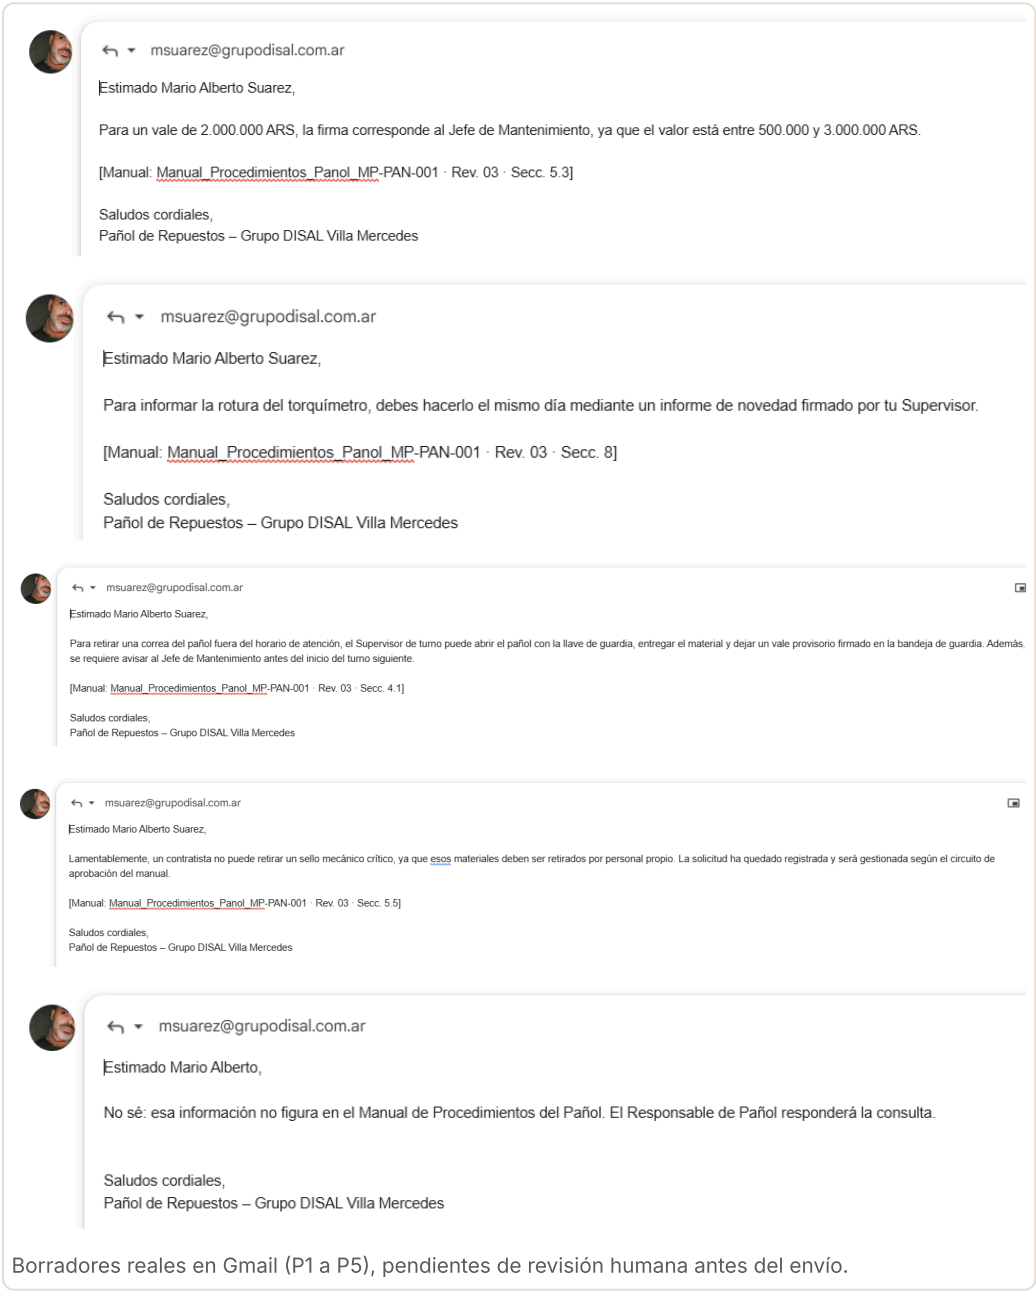
CONCLUSIONES

- **Re-testear la batería completa después de cada cambio:** re-testear solo las preguntas que fallaron habría ocultado la regresión de la P4, que habilitaba un retiro prohibido.
- **El comportamiento es probabilístico:** la P5 se ejecutó 7 veces. Con la v4/v4.1, 2 de 3 corridas fueron correctas desde el modelo; la restante (una paráfrasis con un agregado) motivó la capa 4, que la normaliza al "No sé" oficial (verificado sobre ese texto).
- **Riesgo residual:** omisiones parciales y reformulaciones que pierden el dato pedido. Para el M6: batería nueva de generalización, pregunta original + reformulada al Worker, y set de calibración de más de 20 preguntas.



Ramificación al almacén en verde: `buscar_procedimientos_panol` ejecutado dentro del flujo del M4 (Gmail → memoria → agente → HubSpot → borrador HITL → Slack).

Borradores de la regresión final



Borradores reales en Gmail (P1 a P5), pendientes de revisión humana antes del envío.

PIEZA 5 · CRITERIO: GOBERNANZA

05 Plan de gobernanza de la base de conocimiento

Roles y responsabilidades (RACI)

Actividad	Responsable de Pañol	Jefe de Mantenimiento	Asesor IA (Jefe de Administración)	Usuarios
Redactar o actualizar el manual	R	A	C	I
Aprobar una nueva revisión	C	R / A	I	—
Parsear, curar y re-indexar	C	I	R / A	—
Batería de validación y regresión	R	I	A	—
Revisar los borradores "No sé" (HITL)	R	C	I	I

Frecuencia de revisión

Disparador	Acción
Cambio de procedimiento (cualquier momento)	Nueva revisión del manual → re-ingesta inmediata con el mismo código de documento (overwrite).
Trimestral (fijo)	Revisión de vigencia del MP-PAN-001 junto con el comité de material inmovilizado (sección 11). Montos de aprobación: revisión por inflación.
Mensual	Revisión del log: tasa de `no_match` y `ok_confianza_media`, y "No sé" frecuentes. Una pregunta que se repite sin respuesta indica un vacío en el manual.
Cambio de modelo de embeddings	Re-indexar todo y recalibrar el umbral: los vectores de modelos distintos no son comparables.

Procedimiento de actualización (probado en este checkpoint)

1	2	3	4	5
Parsear	**Curar**	**Overwrite**	**Calibrar**	**Validar**
LlamaParse sobre la revisión aprobada.	Quitar encabezados y pies; jerarquía ##/###; una regla por sección.	Formulario de ingesta: borra por `doc_code` e inserta la versión nueva.	Workflow de calibración: verifica que respuestas y ruido sigan separados.	Batería ciega de 5 preguntas + regresión. Criterio: 5/5 y 0 alucinaciones.

Criterios para eliminar o reemplazar un documento

Criterio	Acción
Revisión nueva aprobada	**Reemplazar** (overwrite por código): nunca conviven dos revisiones vigentes del mismo procedimiento.
Procedimiento derogado o vencido	**Eliminar** sus fragmentos (`DELETE … WHERE doc_code = …`) y registrarlo en el control de revisiones.
Duplica un documento maestro	**Eliminar** el duplicado: evita respuestas contradictorias.
Formato que el parser no estructura bien	**Re-editar la fuente** antes de indexar. No se indexa un documento con tablas rotas.
Términos ambiguos detectados	**Corregir la redacción** (por ejemplo, "Clase A" de criticidad vs. "Clase A" del ABC por valor, una colisión medida en la calibración).

SEGURIDAD Y PRIVACIDAD

Credenciales con mínimo privilegio y dominio restringido. El plan gratuito de Gemini puede usar los datos enviados para mejorar sus productos: con documentos reales de DISAL corresponde el plan pago. Toda respuesta queda como borrador que envía una persona (HITL).