*CURSO IA AVANZADA · n8n · COMISIÓN 97490*

Pre-entrega · Módulo 6 · Ecosistemas Multimedia de Audio (Voice AI)

# Asistente de Pañol v6: Canal Voz

Ensamblado del circuito cerrado conversacional de voz sobre el agente RAG del M5. Telegram → Whisper → AI Agent → ElevenLabs → Telegram, con contención de 200 caracteres, rutas de contingencia y destrucción binaria verificada


01 Síntesis ejecutiva y arquitectura

02 Evaluación de viabilidad (ROI y fatiga cognitiva)

03 C1 · Interceptación binaria (Telegram)

04 C2 · Oídos: OpenAI Whisper

05 C3–C4 · Cerebro y contención de 200 caracteres

06 C5–C6 · Voz (ElevenLabs) y salida binaria

07 C7 · Rutas de contingencia

08 C8 · Compliance y destrucción binaria

09 Protocolo de pruebas P1–P11

10 Latencia y costos

11 Hallazgos H1–H9 e iteraciones

12 Pautas VUI aplicadas y plan de evolución



AUTOR

Mario Suarez


ENTORNO

n8n 2.26.7 self-hosted (Docker) · túnel HTTPS · Telegram @disal_panol_voz_bot

FECHA

12 de octubre de 2026

# 01 Síntesis ejecutiva y arquitectura

El agente del M5 respondía stock y procedimientos con cita del manual, pero dependía de un teclado. El M6 le agrega **oídos** (Whisper) y **voz** (ElevenLabs) en un canal propio de Telegram, pensado para el técnico de mantenimiento que consulta desde la planta con las manos ocupadas. El agente, las tools y la memoria se reutilizan sin cambios: la voz es una **capa de interfaz**.

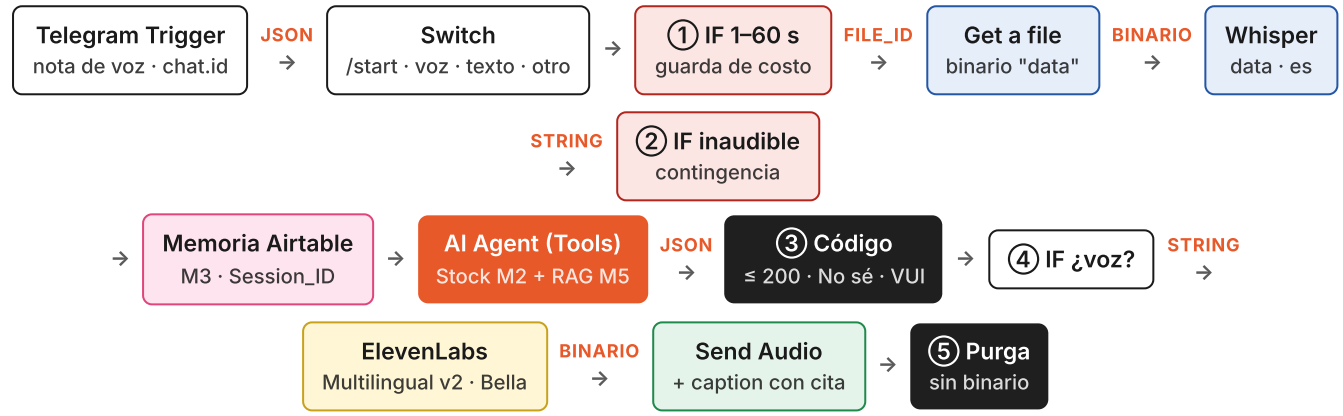
**8 / 8**
componentes de la rúbrica implementados y evidenciados

**10 / 10**
pruebas obligatorias aprobadas (P1–P5, P7–P11)

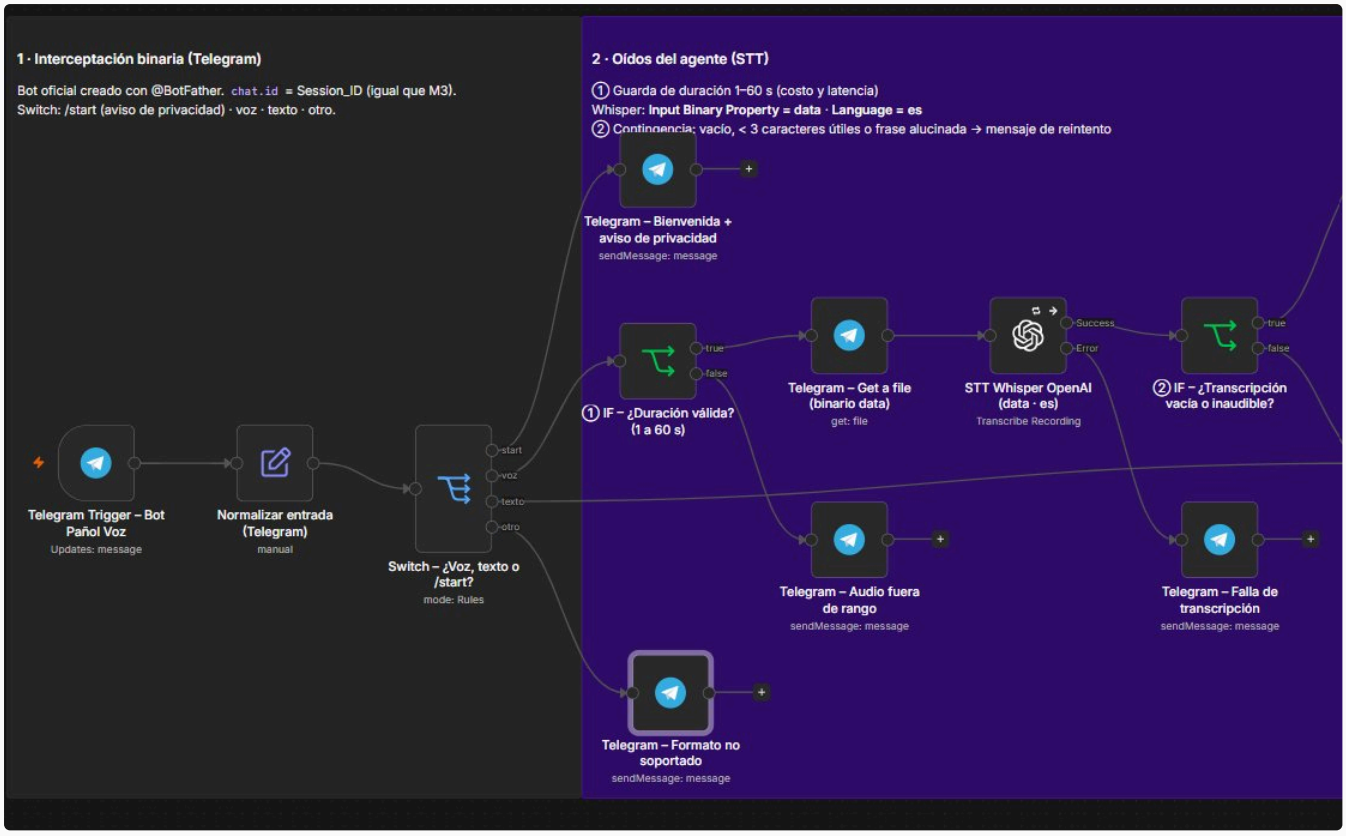
**≤ 200**
caracteres por audio, garantizados por prompt + código

**0**
ejecuciones y binarios de voz persistidos (verificado en disco)

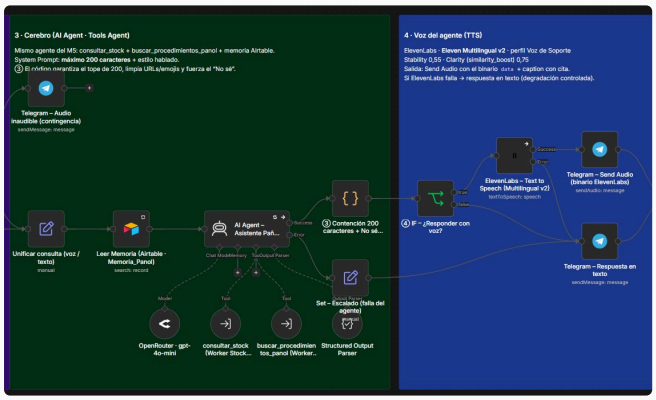
### Arquitectura del circuito cerrado



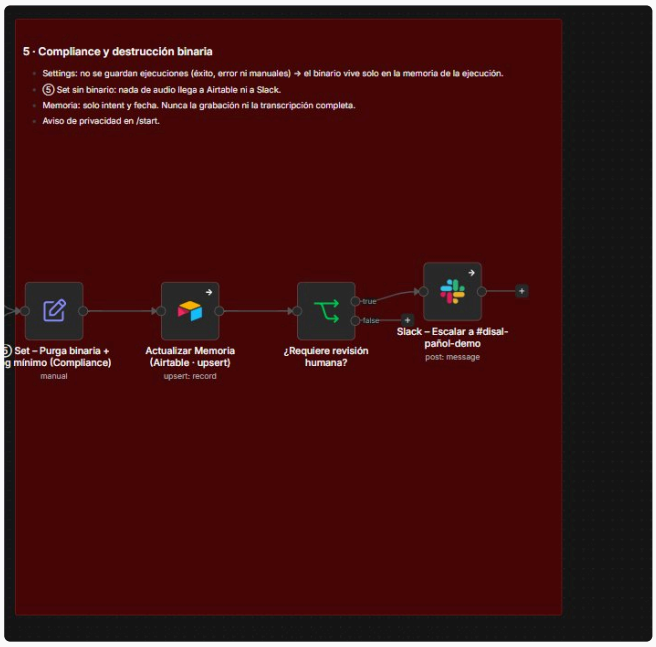

| Decisión de diseño | Justificación |
|---|---|
| **Workflow nuevo "Canal Voz"** | Aísla costos y fallas del canal Email (M4/M5). Reutiliza el mismo agente, sus dos tools (Worker Stock M2 y Worker Procedimientos M5) y la memoria Airtable del M3. |
| **Telegram (bot propio)** | Canal recomendado por la clase para MVP y uso interno: alta en 2 minutos con @BotFather, sin validación de Meta. Bot exclusivo porque Telegram admite un solo webhook por bot. |
| **200 caracteres en dos capas** | El System Prompt lo ordena (rúbrica) y el nodo ③ lo garantiza por código: principio del M5, "el cumplimiento se asegura por código, no por prompt". |
| **Audio + texto (caption)** | El audio sirve al técnico en manos libres; el texto conserva la cita auditable del M5, el código SAP y la descripción oficial, que no se dictan. |
| **Formato espejo** | Consulta escrita → respuesta escrita, sin costo de ElevenLabs. Consulta por voz → audio + texto. |




Lienzo · secciones 1 (Entrada) y 2 (Oídos)




Secciones 3 (Cerebro) y 4 (Voz)




Sección 5 (Compliance y destrucción binaria)

## 02 Evaluación de viabilidad: ROI y resguardo de la fatiga cognitiva

OBJETIVO 1

Antes de construir se aplicó la matriz de viabilidad de la clase a cada tipo de consulta del pañol. La voz se incorporó **solo donde agrega valor**; lo que genera fatiga cognitiva se entrega por texto.

| Consulta del pañol | Clasificación | Formato de salida | Fundamento |
|---|---|---|---|
| **Stock y ubicación de un repuesto** | Alto retorno | Audio + texto | Respuesta corta (≤ 30 s), usuario en campo con las manos ocupadas. |
| **Procedimiento: quién autoriza, horarios** | Alto retorno | Audio + texto con cita | Una regla por respuesta; la cita del manual se lee, no se escucha. |
| **Listado de repuestos de un equipo** | Mixto | Audio resumido + lista escrita | Escuchar 3 o más ítems con códigos y estantes genera fatiga cognitiva: la voz resume y el detalle va por escrito. |
| **Códigos SAP y descripciones** | No por voz | Solo texto | Whisper transcribe mal los alfanuméricos y el TTS los vuelve ininteligibles (H1, H8). |
| **Retiros, reservas, compras** | Fuera de alcance | Texto + escalada | Requieren aprobación humana: el agente registra y deriva al Responsable de Pañol. |

**CASO DE NEGOCIO ILUSTRATIVO (VALIDAR CON LÍNEA BASE)**

Hoy el técnico deja la máquina, camina o llama al pañol para consultar stock (≈ 5 min por consulta). Con el Canal Voz, la consulta toma ≈ 1 min, incluida la latencia de 15–22 s.
20 técnicos × 3 consultas/día × 22 días × 4 min ahorrados ≈ **88 horas-hombre por mes**, frente a un costo operativo estimado de **≈ USD 13/mes** (sección 10).

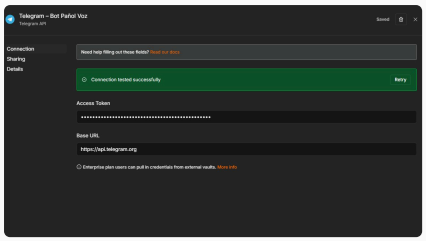
**QUÉ NO SE PROMETE**

Conversación telefónica en tiempo real ni latencia cero: el setup no-code procesa notas de voz en 10–22 s. Tampoco se reemplaza la decisión humana en retiros, compras o reclamos. Es el criterio de "qué no prometer" de la clase.

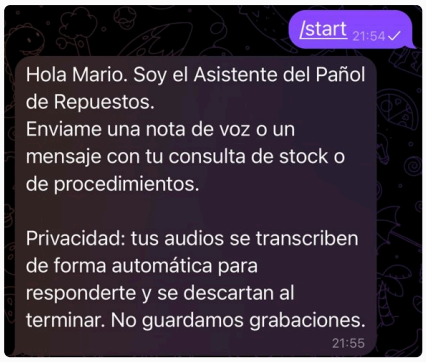
## 03 C1 · Interceptación binaria de entrada (Telegram)

RÚBRICA

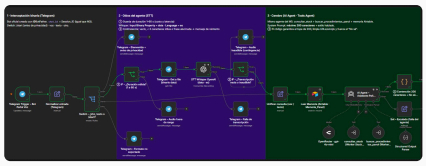
| Nodo | Configuración |
|---|---|
| **Telegram Trigger – Bot Pañol Voz** | Updates: `message` · credencial `Telegram – Bot Pañol Voz` · webhook HTTPS publicado vía túnel |
| **Normalizar entrada** | `session_id = chat.id` (misma identidad que el M3), nombre, canal (voz / texto / otro), `file_id`, `duracion_s` |
| **Switch** | 4 salidas: `start` (bienvenida + aviso de privacidad) · `voz` · `texto` · `otro` (formato no soportado) |
| **Telegram – Get a file** | Resource File · `fileId = {{ $json.file_id }}` · descarga el audio OGG como binario `data` |



Credencial del bot probada



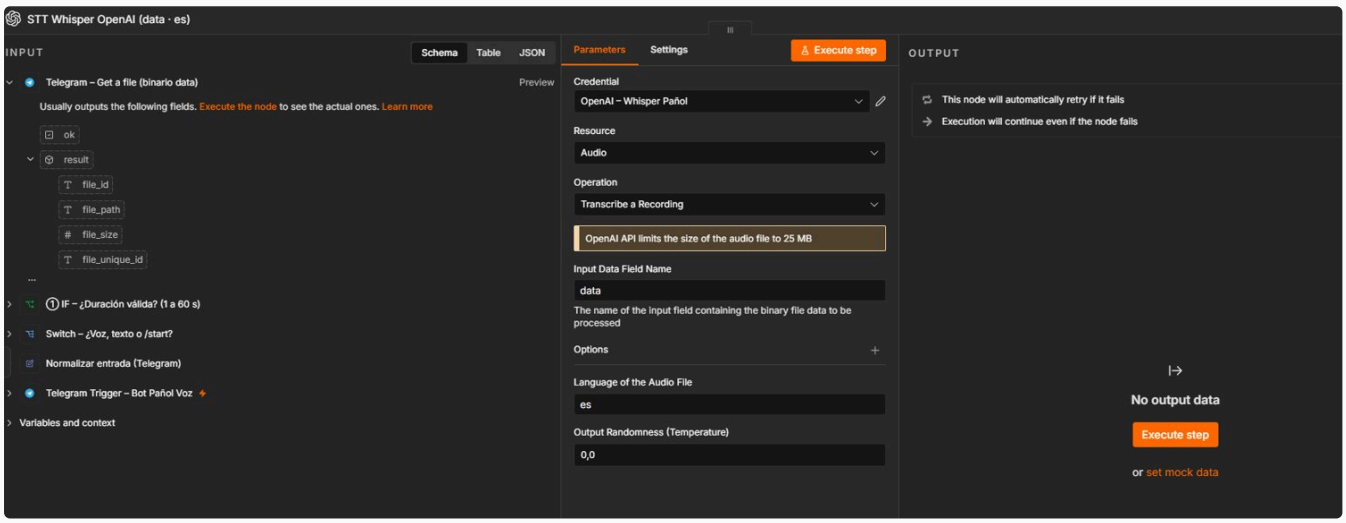

P1 · /start: saludo con nombre y aviso de privacidad



Ejecución: Trigger → Switch (voz) → Get a file → Whisper

## 04 C2 · Oídos del agente: OpenAI Whisper

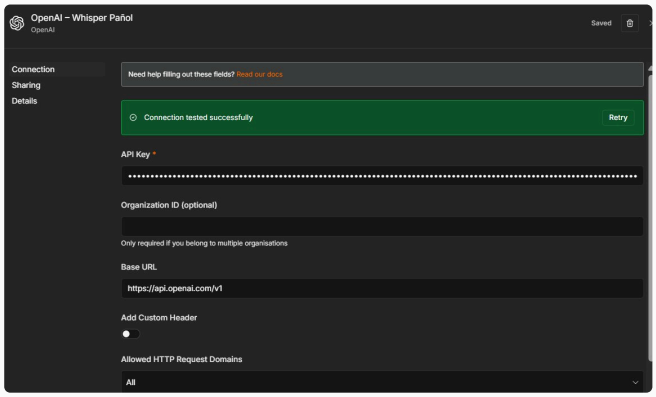
RÚBRICA




STT Whisper OpenAI · Resource Audio · Transcribe a Recording · **Input Data Field Name = data** · **Language = es** · temperatura 0 · reintento automático y salida de error habilitados

### PARÁMETROS EXIGIDOS

- **data**: propiedad binaria que entrega *Get a file*. Es el valor por defecto del nodo, por eso el JSON exportado no la repite.
- **es**: fijado en *Options* → *Language*; evita la detección de idioma y reduce la latencia (Whisper: 1,6–2,6 s por audio en las pruebas).
- Credencial `OpenAI – Whisper Pañol` con saldo prepago de USD 5, alertas al 80 % y 100 % y dominio restringido a la API de OpenAI.




Credencial OpenAI probada

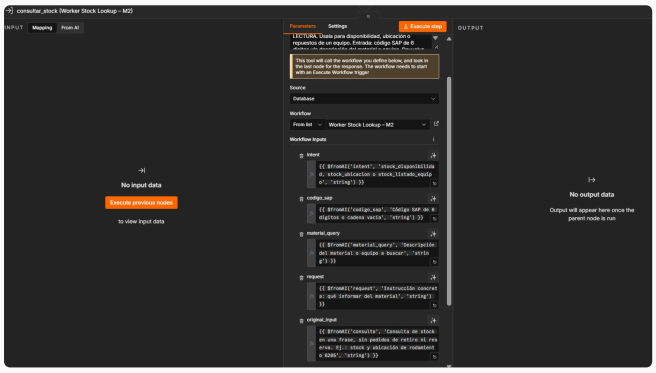
```
// Extracto del JSON exportado (STT Whisper OpenAI)
"resource": "audio", "operation": "transcribe",
"options": { "language": "es", "temperature": 0 }      // binaryPropertyName = "data" (por defecto)
"retryOnFail": true, "onError": "continueErrorOutput"
```

## 05 C3–C4 · Cerebro (AI Agent) y contención financiera

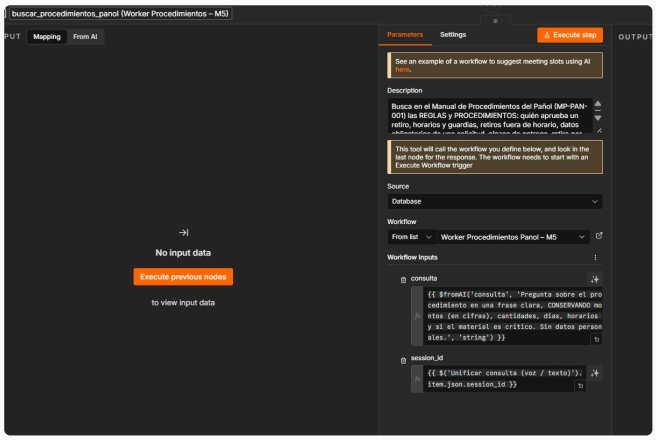
RÚBRICA

El texto transcripto entra al **AI Agent en modo Tools Agent** (nodo `@n8n/n8n-nodes-langchain.agent`), con el mismo modelo y las mismas tools del M5. Un *Set* unifica las consultas de voz y de texto en un contrato único (`session_id`, `canal`, `texto`) antes de la memoria y del agente.

| Sub-nodo | Configuración |
|---|---|
| **Modelo** | OpenRouter · `openai/gpt-4o-mini` · temperatura 0,2 · max tokens 800 |
| **Tool: consultar_stock** | Worker Stock Lookup – M2 (sub-workflow publicado) · entradas con `$fromAI()` |
| **Tool: buscar_procedimientos_panol** | Worker Procedimientos – M5 (RAG sobre PGVector, Top-K 3, umbral 0,66) · cita armada desde metadatos |
| **Structured Output Parser** | JSON Schema con `respuesta`, evidencia y `fuente_rag` obligatorios · **Auto-Fix Format** activo (H5) |




Tool consultar_stock con inputs $fromAI




Tool buscar_procedimientos_panol (RAG M5)

### C4 · Regla de contención financiera en el System Message

```
## CONTENCIÓN FINANCIERA (REGLA OBLIGATORIA)
Limitá SIEMPRE la longitud de tu respuesta escrita (campo "respuesta") a un MÁXIMO DE 200 CARACTERES,
contando letras, espacios y signos. Cada carácter se cobra en la API de audio. PROHIBIDO superar los 200
caracteres.
Si la información no entra, priorizá el dato que responde la pregunta y omití el resto.
## ESTILO HABLADO (aplica SOLO al contenido del campo "respuesta", nunca reemplaza el formato JSON)
Frases cortas Sujeto + Verbo + Predicado · puntos seguidos para pausas · PROHIBIDO URLs, emojis, viñetas,
citas y códigos SAP.
10. FORMATO DE SALIDA OBLIGATORIO: tu respuesta final es SIEMPRE el JSON del esquema, aunque la
herramienta devuelva texto largo.
```

### Garantía por código · nodo ③ (Code, v3)

| Control | Qué hace |
|---|---|
| **Tope duro de 200** | Recorta la versión hablada en el último punto real (nunca en "3." de una lista) · `formato_voz`: completa / recortada / resumen_listado / no_se |
| **Normalización para la voz** | "Est." → estante · "N°" → número · "A-01-04" → "A, 1, 4" · códigos alfanuméricos deletreados · sin URLs, emojis ni markdown |
| **"No sé" determinista** | Sin evidencia literal, cita sin evidencia o texto que admite no saber → frase oficial + `requiere_revision` (las capas del M5) |
| **Validación de cita** | `fuente_rag` solo acepta `[Manual: …]`; el código SAP y el material se rescatan a sus campos (H2) |

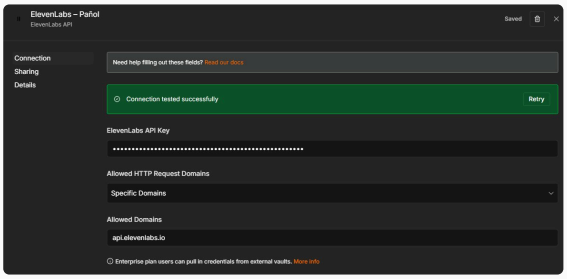
```
// Salida real del nodo ③ · P3 (procedimiento por voz)
"intent": "consulta_procedimiento", "fuente_rag": "[Manual: Manual_Procedimientos_Panol_MP-PAN-001 · Rev. 03 · Secc. 4.1]",
"respuesta_voz": "El Supervisor de turno puede autorizar el retiro. Debe avisar al Jefe de Mantenimiento antes del siguiente turno.",
"caracteres_modelo": 113, "caracteres_tts": 113, "recorte_aplicado": false
```

## 06 C5–C6 · Voz del agente (ElevenLabs) y salida multimedia binaria RÚBRICA

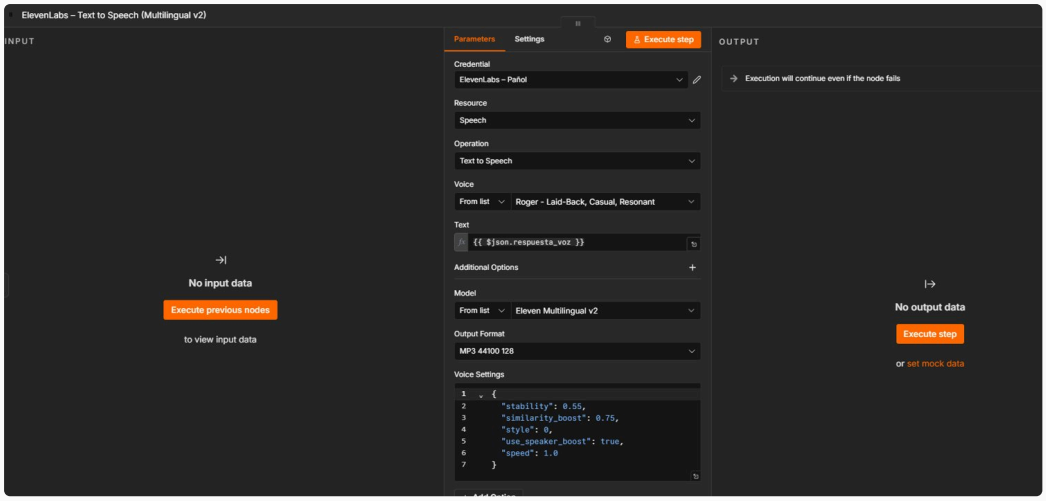
| Parámetro | Valor final (JSON exportado) |
|---|---|
| **Nodo** | ElevenLabs (nodo verificado `@elevenlabs/n8n-nodes-elevenlabs` v0.2.4) · Speech → Text to Speech |
| **Modelo** | **Eleven Multilingual v2** |
| **Voz** | **Bella** – Professional, Bright, Warm (voz predeterminada, habilitada por API en plan Free) |
| **Stability** | **0,50** · perfil "Voz de Soporte" (50–60 %) |
| **Clarity / Similarity** | **0,80** |
| **Style · Speaker boost · Speed** | 0,1 · activado · 1,1 |
| **Texto** | `{{ $json.respuesta_voz }}` (≤ 200, normalizado) |
| **Formato** | MP3 44.1 kHz 128 kbps · salida de error → respuesta en texto |



Nodo verificado instalado



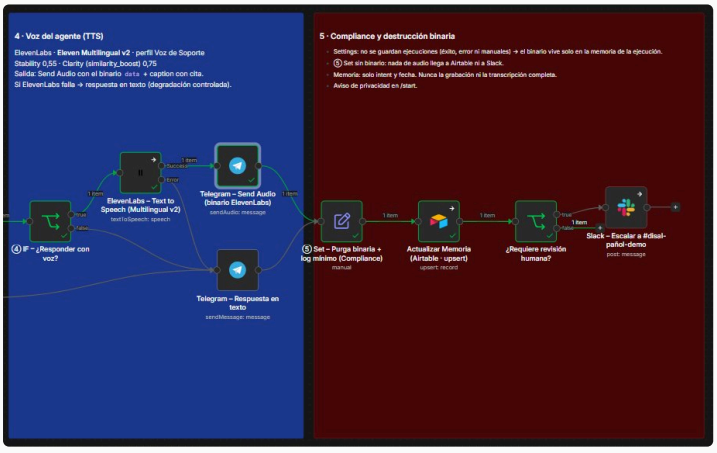
Credencial restringida a la API de ElevenLabs (clave limitada a TTS, con tope de créditos)



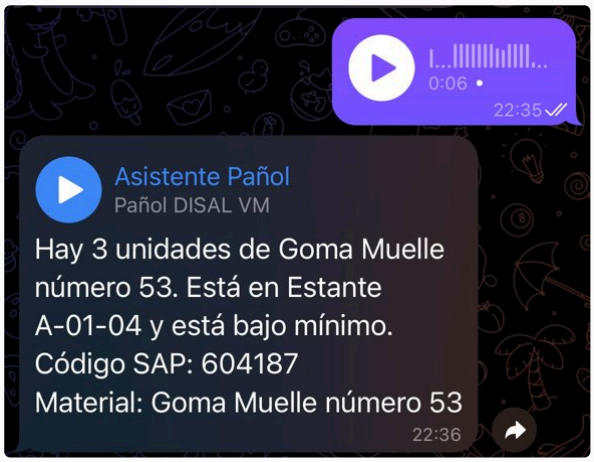

Configuración visual del nodo. La captura es de la primera prueba (voz Roger, stability 0,55 / similarity 0,75); la voz y los sliders finales son los de la tabla (H1 y H3)

## C6 · Salida: Send Audio con el binario de ElevenLabs

| Nodo | Configuración |
|---|---|
| **Telegram – Send Audio** | Operation `sendAudio` · Binary File ON · propiedad `data` (binario de ElevenLabs) · `chatId` dinámico · caption = respuesta + código SAP + material + cita |
| **④ IF ¿Responder con voz?** | Si la consulta llegó por texto → respuesta en texto, sin consumir ElevenLabs |




IF ④ → ElevenLabs → Send Audio → ⑤ Purga → memoria




P2 · nota de voz → audio (Bella) + caption con código SAP y material

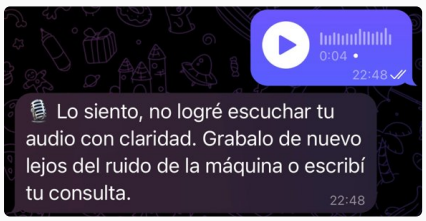
## 07 C7 · Rutas de contingencia no-code

RÚBRICA

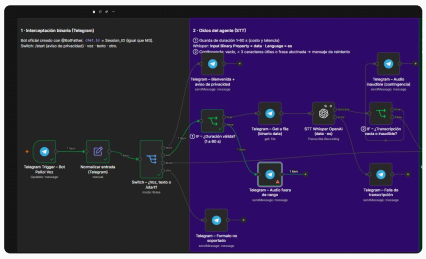
| Contingencia | Condición | Ruta segura |
|---|---|---|
| ② **Audio vacío o inaudible** | `caracteres útiles < 3` o frase típica que Whisper inventa ante el silencio (Amara.org, "gracias por ver") | Mensaje de reintento en texto; el agente y ElevenLabs no se ejecutan |
| ① **Duración fuera de rango** | `duracion_s < 1` o `> 60` | Aviso con la duración; no se descarga ni se transcribe (costo cero) |
| **Falla de Whisper** | Error de API (2 reintentos) | "No pude procesar tu audio..." |
| **Falla del agente** | Error tras 2 reintentos | Set escalado → texto al usuario + Slack |
| **Falla de ElevenLabs** | Salida de error del nodo | Degradación controlada: la respuesta llega en texto |
| **"No sé" / revisión** | `requiere_revision = true` | Escalada a #disal-pañol-demo (Slack) |



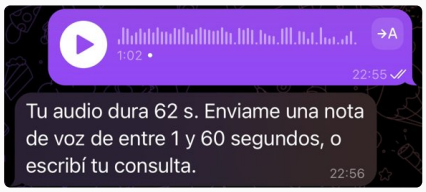
P5 · silencio: IF ② sale por true; el resto del flujo queda sin ejecutar



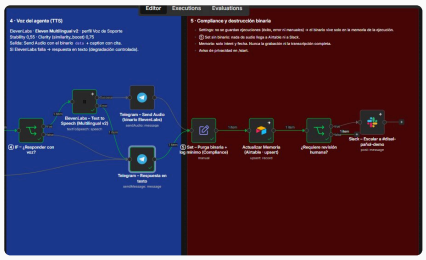

P5 · mensaje de reintento



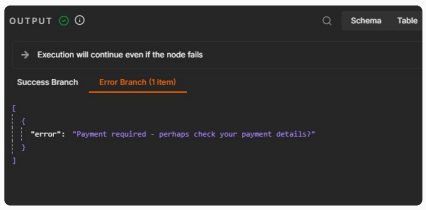
P7 · audio de 62 s: IF ① sale por false; Whisper no se ejecuta



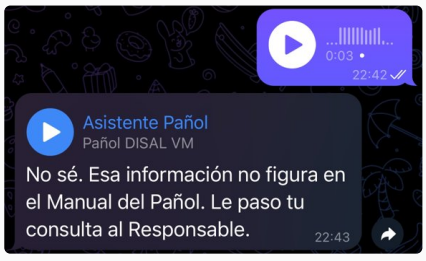

P7 · aviso de duración



P10 · ElevenLabs falla (402) → Respuesta en texto




Error capturado en la salida de error



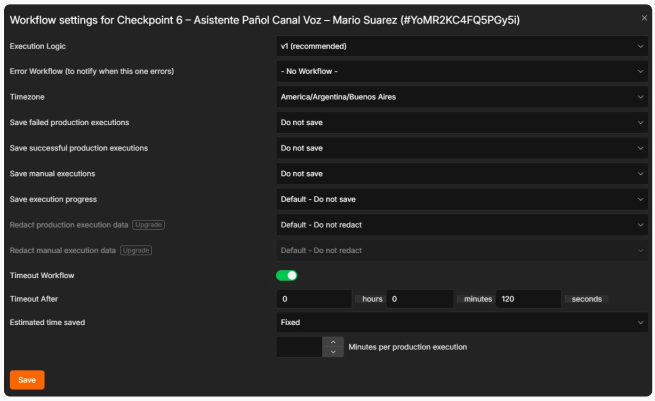

P4 · "No sé" oficial + escalada

# 08 C8 · Marco de compliance y destrucción binaria

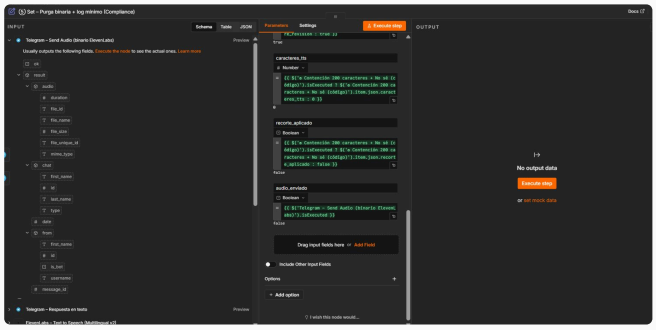
RÚBRICA

Objetivo: que la voz del usuario se procese **solo en la memoria de la ejecución** y no quede persistida en n8n al cerrar el flujo. El control se diseñó en cinco capas y se verificó con evidencia independiente en producción.

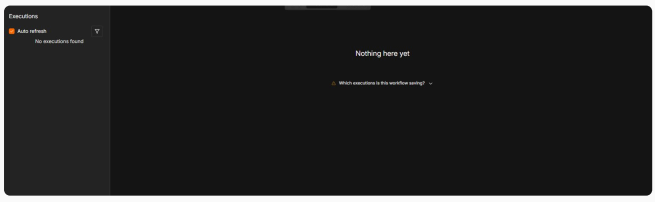
| # | Capa | Diseño | Evidencia |
|---|---|---|---|
| 1 | **Settings del workflow** | Ejecuciones exitosas, fallidas y manuales en *Do not save*; sin progreso intermedio; timeout de 120 s | Captura de Settings |
| 2 | **⑤ Set de purga** | *Include Other Input Fields* desactivado: solo pasan los campos de log definidos, nunca el binario | Captura del nodo |
| 3 | **Base de datos de n8n** | Sin ejecuciones persistidas | Executions: "No executions found" |
| 4 | **Disco del contenedor** | Sin archivos de binaryData | `find … binaryData \| wc -l` = 0 antes y después de un audio |
| 5 | **Memoria del negocio** | El Canal Voz solo escribe intent y fecha en Airtable; nunca audio ni transcripción completa | Airtable: Ultimo_Intent |



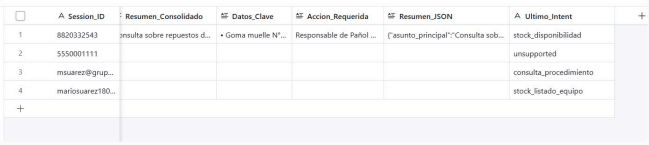

Capa 1 · Settings: Do not save (fallidas, exitosas, manuales y progreso) · timeout 120 s · zona horaria explícita



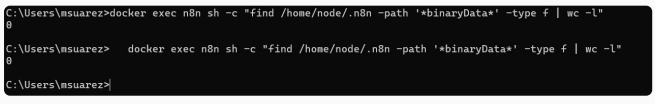
Capa 2 · ⑤ Set: Include Other Input Fields = OFF




Capa 3 · sin ejecuciones guardadas tras pruebas en producción




Capa 5 · el Canal Voz actualiza solo Ultimo_Intent y la fecha. Los resúmenes provienen del canal texto (M3) y no contienen audio




Capa 4 · 0 archivos binarios antes y después de procesar una nota de voz

**AVISO Y ALCANCE**

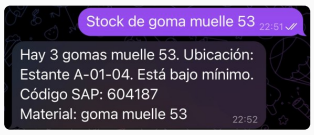
El usuario recibe en /start el aviso *"tus audios se transcriben… y se descartan al terminar"*. Límite documentado: la nota original permanece en el chat de Telegram del usuario, y OpenAI y ElevenLabs procesan el contenido según sus políticas de API; la retención cero en esos proveedores requiere planes empresariales. La opción *Redact execution data* de n8n es paga; se aplicó el control más estricto disponible: no guardar.

## 09 Protocolo de pruebas de punta a punta

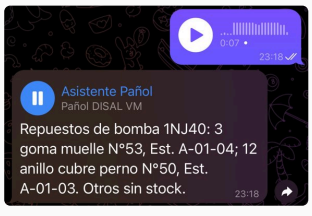
| # | Prueba | Entrada | Resultado | Car. TTS |
|---|---|---|---|---|
| P1 | **Bienvenida + privacidad** | /start | ✅ Saludo + aviso | — |
| P2 | **Stock por voz** | "¿Cuánto stock hay de goma muelle 53 y dónde está?" | ✅ tras H1–H4 | 84–93 |
| P3 | **Procedimiento + cita (RAG)** | "¿Quién me autoriza sacar un repuesto crítico el domingo a la noche?" | ✅ Secc. 4.1 citada | 113 |
| P4 | **Fuera del manual** | "¿Cuál es el interno del Supervisor de turno?" | ✅ "No sé" + Slack | 92 |
| P5 | **Silencio** | Nota de 4 s sin voz | ✅ Contingencia ② | 0 |
| P7 | **Audio largo** | Nota de 62 s | ✅ Guarda ① | 0 |
| P8 | **Consulta por texto** | "Stock de goma muelle 53" | ✅ Texto, sin TTS | 0 |
| P9 | **Listado largo** | "Todos los repuestos de la bomba 1NEJ40, con stock y ubicación" | ✅ tras H5–H6 | 137 |
| P10 | **Falla de TTS** | Error 402 de ElevenLabs | ✅ Degradación a texto | — |
| P11 | **Destrucción binaria** | Nota de voz en producción | ✅ 0 ejecuciones / 0 binarios | — |
| P6 | **Ruido de planta** | — | Pendiente | — |



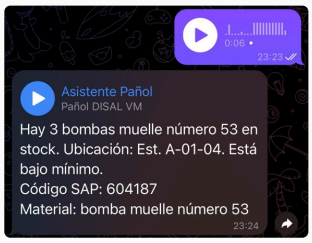
P3 · regla + cita en el texto



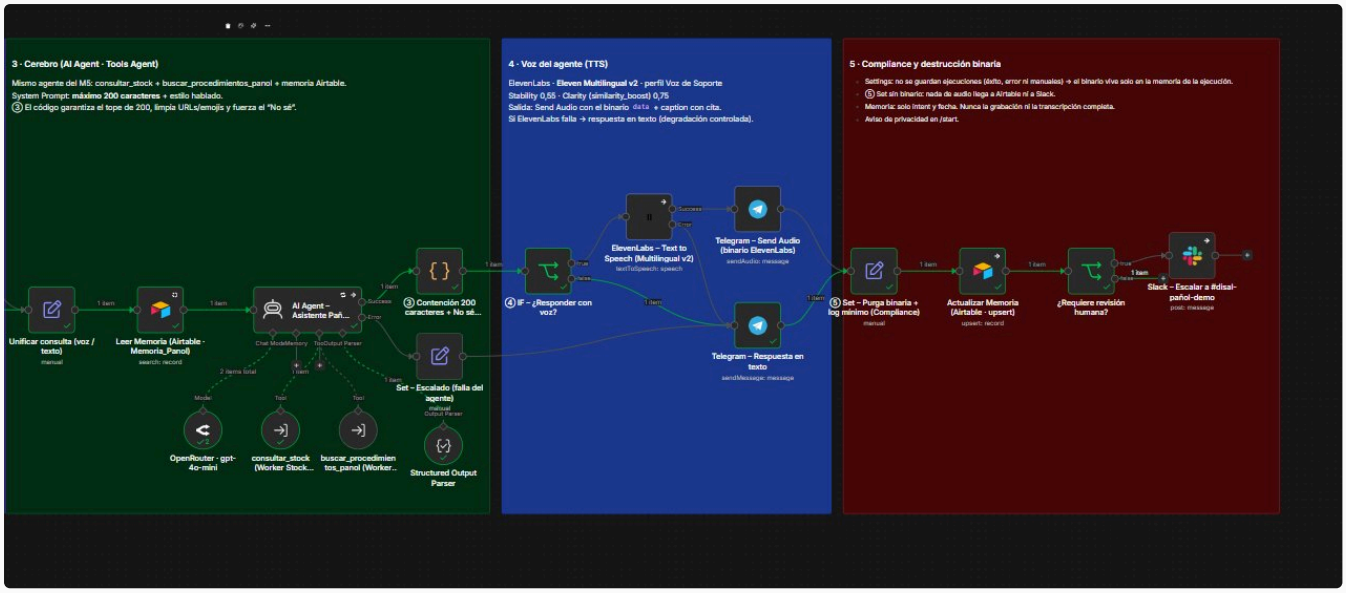
P8 · texto → texto



P9 · listado resumido



Producción · workflow publicado



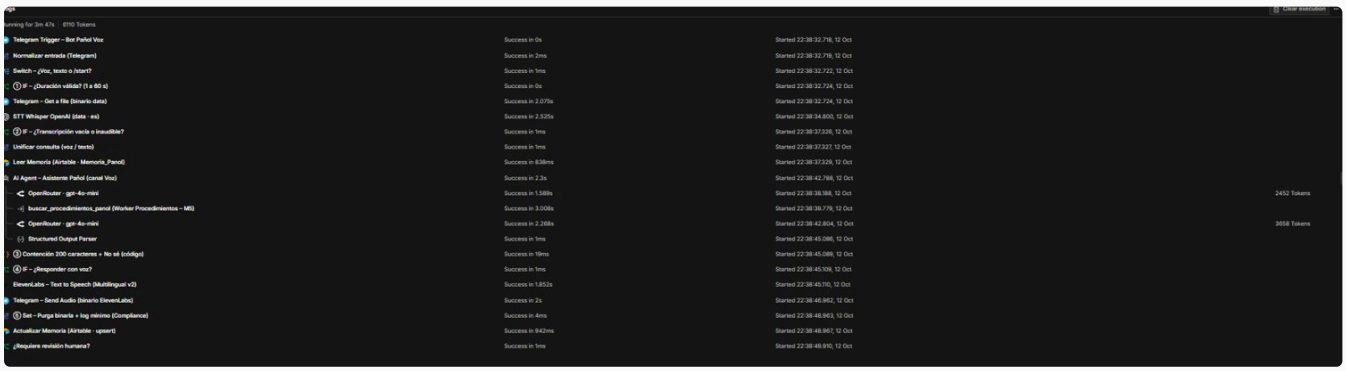

P8 · consulta escrita: Whisper y ElevenLabs no se ejecutan (formato espejo)

## 10 Latencia y costos

| Prueba | Latencia percibida | Composición |
|---|---|---|
| **P8 · stock por texto** | 10,6 s | Agente ≈ 7,5 s (Worker Stock 3,8 s) · Airtable 2,4 s · envío 0,9 s |
| **P4 · "No sé" por voz** | 14,7 s | Get file 1,8 · Whisper 1,6 · Airtable 2,1 · agente 5,4 · ElevenLabs 1,8 · envío 2,0 |
| **P3 · procedimiento por voz** | 16,2 s | Get file 2,1 · Whisper 2,5 · Airtable 0,8 · agente 7,0 (RAG 3,0) · ElevenLabs 1,9 · envío 2,0 |
| **P9 · listado por voz** | 21,9 s | Get file 2,1 · Whisper 1,7 · Airtable 2,4 · agente 10,1 (Worker Stock 5,9) · ElevenLabs 2,8 · envío 2,7 |

**KPI DE LA CLASE (< 8 S): NO SE CUMPLE EN EL ENTORNO DE PRUEBAS**

El razonamiento pesa ≈ 45 %, porque el agente hace dos vueltas al modelo más la tool, con evidencia y cita. Telegram suma ≈ 4 s, por correr n8n en local detrás de un túnel, y Airtable entre 0,8 y 2,4 s. Whisper y Multilingual v2 son los modelos que exige la rúbrica, no los más rápidos. Se prioriza la precisión con evidencia sobre la velocidad.



Logs P3 · duración por nodo (base del desglose)

### Costo por interacción (ilustrativo, precios a validar)

| Componente | Supuesto | USD |
|---|---|---|
| Whisper | 6 s ≈ 0,1 min × 0,006 | 0,0006 |
| gpt-4o-mini | ≈ 5.800 tokens (medido) | 0,0010 |
| ElevenLabs | ≈ 110 car. (plan Starter) | 0,0183 |
| **Total** | | **≈ 0,020** |

ElevenLabs explica ≈ 90 % del costo: por eso el tope de 200 caracteres es obligatorio. 660 consultas/mes ≈ USD 13 y ≈ 73.000 caracteres, lo que requiere un plan de ElevenLabs superior al Free (10.000 créditos/mes, que alcanzan para unas 90 respuestas).

### Plan de reducción de latencia

| Acción | Ahorro |
|---|---|
| n8n en servidor (sin túnel) | −3 a −4 s |
| Pre-filtrado determinista del Worker Stock (pendiente M4) | −2 a −4 s |
| Memoria en caché o en paralelo | −1 a −2 s |
| ElevenLabs Flash (si la rúbrica lo permite) | −1 s |
| **Objetivo en producción** | **≈ 8–10 s** |

## 11 Hallazgos e iteraciones

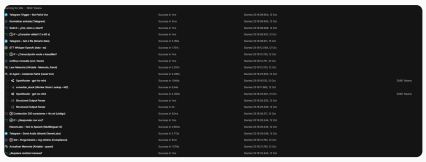
| # | Síntoma | Causa raíz | Corrección |
|---|---|---|---|
| H1 | **Voz robótica y lenta; códigos ininteligibles** | Voz nativa en inglés (Roger); abreviaturas y códigos leídos literalmente | Normalización para la voz en ③; voz nativa en español; speed 1,1 |
| H2 | **Datos de stock en `fuente_rag`; nombraba el equipo** | El modelo confundía los campos | Validación de citas por código; reglas 8 y 9 |
| H3 | **Sin audio (402 Payment required)** | Voz de la Voice Library bloqueada por API en el plan Free | Voz predeterminada Bella; la contingencia entregó la respuesta en texto |
| H4 | **"Est." leído como "Estación"** | Abreviatura ambigua | Regla 9: "Est." = ESTANTE |
| H5 | **Bucle de 6 vueltas: 63 s y 33.000 tokens** | Tras un listado largo, el modelo respondió en prosa y el parser lo rechazó | Auto-Fix Format + regla 10. Resultado: 5.800 tokens (−82 %) y 21,9 s |
| H6 | **Audio cortado en "3."** | Numeración tomada como fin de frase; la normalización superaba los 200 caracteres | ③ v3: corte en punto real, resumen de listados, `formato_voz` |
| H7 | **No se podía publicar** | 2 nodos de contingencia sin credencial (el modo manual no los valida) | Credenciales asignadas; la validación al publicar sirvió de control |
| H8 | **"Bomba muelle" / "1S53" en lugar de "goma muelle"** | Error fonético de Whisper que el agente repetía | Regla 5: material desde el dato oficial del stock ✅. Persiste en la frase hablada: límite documentado |
| H9 | **Ejecución cancelada guardada con audio** | n8n persiste las ejecuciones canceladas aunque la configuración diga Do not save | Borrado manual y revisión de Executions en el procedimiento; en servidor, límite de antigüedad de ejecuciones |



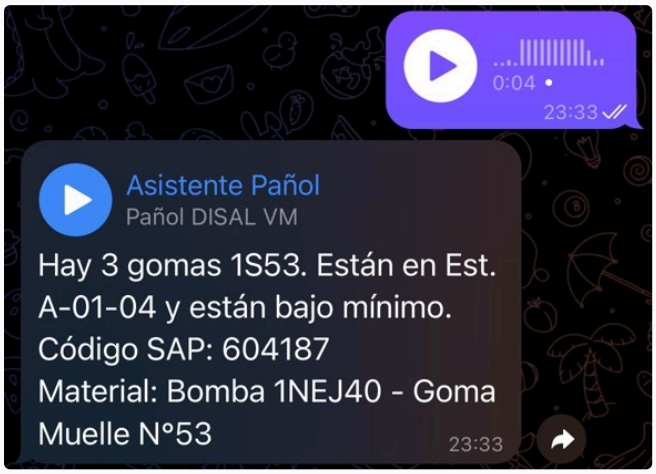
H5 · antes: 6 vueltas con el parser en rojo (32.959 tokens)



H5 · causa: salida en prosa, sin JSON



H5 · después: una vuelta, 5.822 tokens




H8 · material oficial en el texto; frase hablada con error fonético

**LECCIONES DEL MÓDULO**

- La voz amplifica los errores de formato: cada carácter que llega a ElevenLabs se cobra y se escucha.
- Las listas, los códigos y las citas se entregan por texto; el audio comunica una sola idea.
- Las rutas de contingencia son las menos probadas y las primeras que fallan en producción (H7).
- Un parser estricto sin auto-corrección multiplica costo y latencia ante un solo desvío del modelo (H5).
- El compliance se demuestra con evidencia en cada capa, no con la configuración sola (H9).

## 12 Pautas VUI aplicadas y plan de evolución

OBJETIVO 3

| Principio VUI (clase) | Implementación |
|---|---|
| **Claridad absoluta** | Voz Bella, Multilingual v2, speed 1,1 · normalización de abreviaturas, ubicaciones y códigos |
| **Brevedad estricta** | ≤ 200 caracteres (≈ 12–15 s de audio) por prompt y por código · listados resumidos |
| **Tono apropiado** | Perfil "Voz de Soporte" (stability 0,50) · tono ágil y orientado a procesos (perfil Telegram) |
| **Límites honestos** | "No sé" oficial sin inventar · escalada humana · aviso de reintento ante audio inaudible |
| **Sin "caja negra"** | Confirmación verbal de acciones registradas · el estado se informa también por texto |
| **Privacidad del payload** | Aviso en /start · procesamiento volátil · memoria sin audio ni transcripción |

| Pendiente → M7+ | Evolución propuesta |
|---|---|
| **Latencia de 15–22 s** | n8n en servidor, pre-filtrado del Worker Stock y memoria en caché (objetivo ≈ 8–10 s) |
| **Errores fonéticos con la jerga de planta** | Diccionario de pronunciación / vocabulario técnico del pañol para STT y TTS |
| **P6 · ruido de planta** | Batería en campo con 2–3 técnicos (prueba ciega de la clase) y tasa de transcripción correcta |
| **Retención en proveedores** | Evaluar planes con retención cero antes de usar datos reales de DISAL |
| **Escala de ElevenLabs** | Plan pago según volumen (≈ 73.000 caracteres/mes estimados) |

**"La voz se incorporó donde ahorra tiempo al técnico; todo lo demás llega por escrito."**

Circuito cerrado Telegram → Whisper → AI Agent RAG → ElevenLabs → Telegram, con contención financiera garantizada por código y destrucción binaria verificada en cuatro capas.